

令和7年度

修士論文

A horizontal row of 18 empty circles, each with a thin black outline, arranged in a single horizontal line.

A horizontal row of fifteen empty circles, evenly spaced, used as a visual element in a document.

公立千歳科学技術大学大学院理工学研究科

丰田将大

目次

第 1 章	序論	1
1.1	研究背景	1
1.2	研究の動機と着眼点	2
1.3	仮説	3
1.4	研究目的	5
第 2 章	参考技術	6
2.1	時間領域有限差分法 (FDTD 法)	6
2.2	Multi-Mode Interferometer (MMI)	7
2.3	畳み込みニューラルネットワーク (CNN)	8
2.4	超解像技術	9
2.5	画像相互変換技術	9
2.6	評価指標	11
2.7	光通信における波長帯	12
第 3 章	超解像によるシミュレーションの効率化	14
3.1	はじめに	14
3.2	機械学習による超解像の原理	14
3.3	研究手順	15
3.4	結果	19
3.5	まとめ	21
第 4 章	画像相互変換による設計資産の活用	23
4.1	はじめに	23

4.2	電磁界分布画像から強度分布画像への変換	23
4.3	強度分布画像から電磁界分布画像への変換	30
4.4	まとめ	40
第5章 結論		41
5.1	本研究の総括	41
5.2	本研究の意義	42
5.3	今後の展望	42
参考文献		43
参考文献		43
謝辞		45

第1章

序論

1.1 研究背景

近年、クラウドコンピューティングや5G通信の普及に伴い、世界的に情報通信量が爆発的に増加している[1](図1.1)。これに伴い、データセンターなどにおける情報処理機器の消費電力増大が課題となっている。この課題を解決する技術として、低消費電力かつ大容量伝送が可能な光集積回路(PIC: Photonic Integrated Circuit)が注目されている。現在のPICは、光信号の伝送のみならず、波長分割多重、スイッチング、変調、受光、モニタリングなど多岐にわたる機能をワンチップ上で実現しており、その回路規模は年々大規模化・複雑化の一途をたどっている。

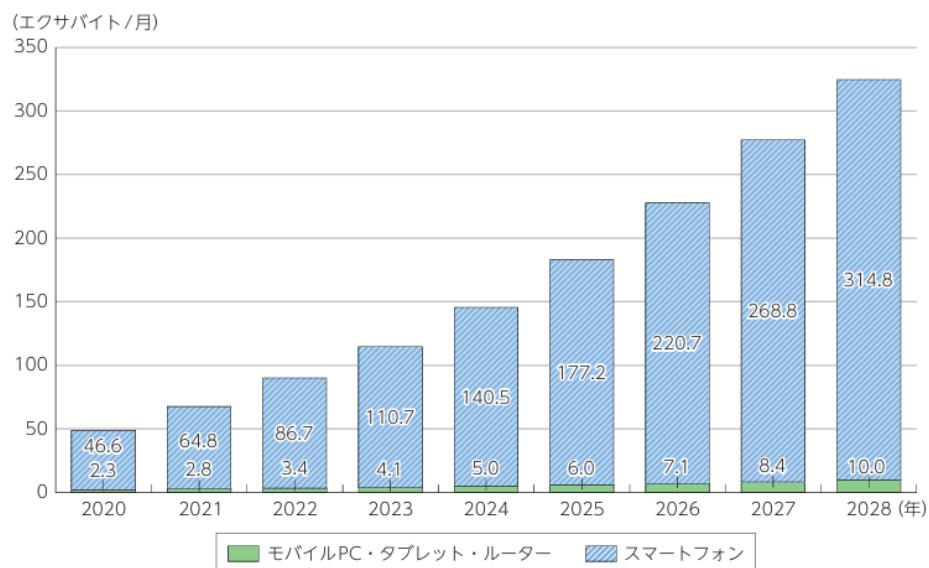


図1.1 世界の通信トラフィックの推移予測[1]。今後も急激な増加が見込まれている。

PIC の設計プロセスにおいて、電磁界シミュレーションはデバイスの特性を予測・最適化するために不可欠な工程である。しかし、回路の大規模化に伴い、シミュレーションに必要な計算資源（メモリや計算時間）の確保が深刻な問題となっている。PIC を実現するために有望視されているプラットフォームシリコンフォトニクスがある。シリコンをコアとし、その酸化膜をクラッドとするため、コアとクラッドの屈折率比を大きくとれるため、PIC の寸法を極限まで小さくすることができる。しかしながら、そのシミュレーションでは、コアとクラッドの屈折率比が小さいことを前提とするビーム伝搬法などを用いることができず、Maxwell 方程式を離散化して解く時間領域有限差分 (FDTD: Finite-Difference Time-Domain) 法を用いる必要がある。FDTD 法を用いて高精度な結果を得るためには、計算メッシュの微細化に伴い計算コストは指数関数的に増大する（図 1.3）。

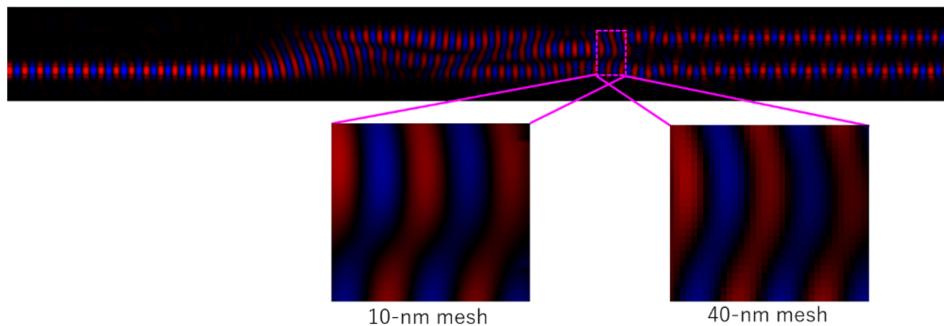


図 1.2 FDTD シミュレーションにおけるメッシュサイズと電磁界分布の解像度の関係。微細なメッシュは高精度だが計算コストが高く、粗いメッシュは高速だが情報量が失われる。

この計算コスト増大の問題に対し、設計効率を維持・向上させるためには、従来の設計手法の枠を超えた新たなアプローチが必要不可欠である。特に近年、画像認識や生成の分野で著しい成果を上げている深層学習（ディープラーニング）技術の PIC 設計への応用が期待できる [2]。

1.2 研究の動機と着眼点

本研究では、PIC 設計の効率化という課題に対し、機械学習を用いた画像処理技術のアプローチから、二つの観点で解決を試みる。

第一のアプローチは、「シミュレーション自体の計算コスト削減」である。FDTD 法などのシミュレーションでは、粗いメッシュを用いれば計算時間は短縮されるが、得られる電磁界分布の解像度が低下し、設計に必要な精度が得られないというトレードオフが存在する（図 1.2 参照）。ここで、低解像度の画像から高解像度の画像を推定する「超解像（Super-Resolution）」技術を適用

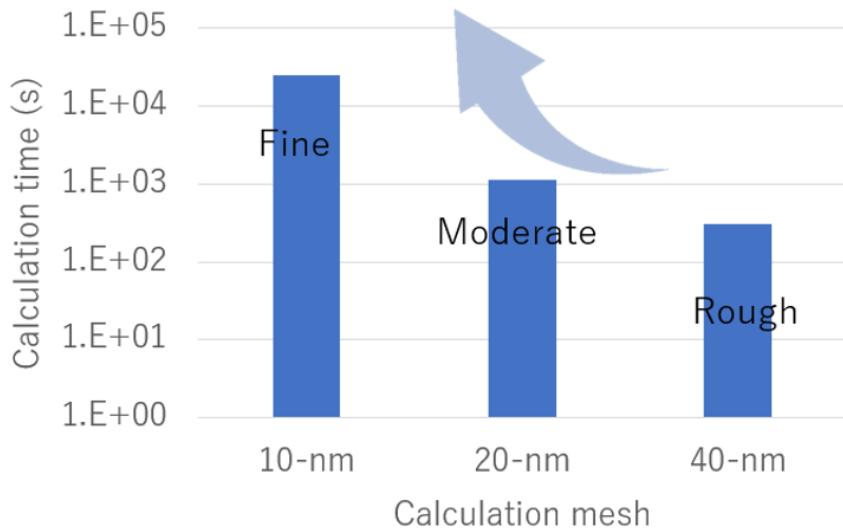


図 1.3 図 1.2 を計算したときにかかるメッシュサイズごとの計算時間。

できれば、粗いメッシュによる高速な計算結果から、微細メッシュと同等の詳細な情報を復元できる可能性がある。

第二のアプローチは、「過去のシミュレーションデータの再利用」である。設計過程では膨大な数のシミュレーションが行われるが、所望の設計パラメータを得たのちは、詳細な 3 次元電磁場分布といった数値データは容量の都合で破棄されることが多く、データの再利用は難しい。この場合であっても確認用の「可視化画像」（電磁界分布画像や強度分布画像）は比較的容量も小さく、残されることが多い。これらの画像データには、デバイス内の光の振る舞いに関する重要な情報が含まれている。もし、この情報が再利用可能になれば、再計算を行うことなく、手元の画像アーカイブから必要な情報を即座に取得することが可能となり、設計プロセスを大幅に効率化できる。本研究では、これら「超解像」と「再利用」という二つのタスクを、機械学習を用いた画像生成・変換問題として統一的に捉え、それぞれの有効性を検証する。

1.3 仮説

本研究では、それぞれのタスクに対して以下の仮説を立てる。

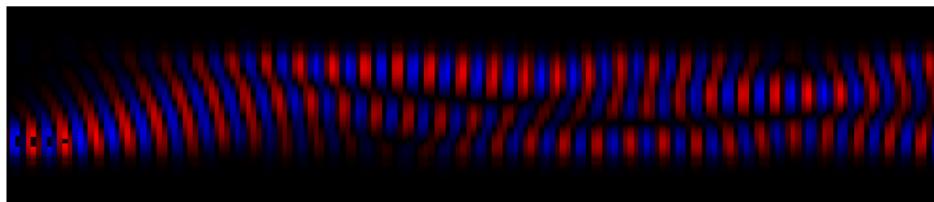
超解像に関する仮説

粗いメッシュで計算された低解像度の電磁界分布画像であっても、光の波動としての基本的な振る舞いは保存されている。CNN を用いることで、低解像度・高解像度ペアデータから、メッシュの粗さによって失われた情報を学習し、低解像度のシミュレーション結果に対しても高精度な高解像度画像を再構成できると仮定する。

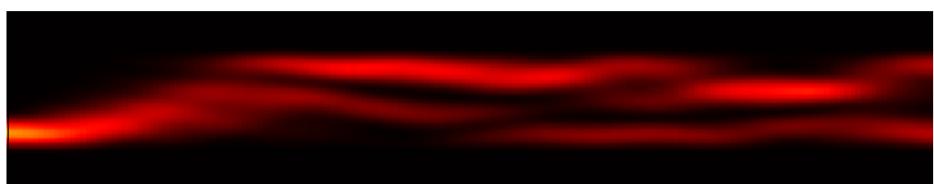
画像相互変換に関する仮説

電磁界シミュレーションから得られる電磁界分布画像と、強度分布画像の間には、物理的な対応関係が存在する。図 1.4 に示すように、両者は見た目が大きく異なるが、熟練した設計者が視覚的に推測可能であるのと同様に、機械学習によって推測可能であると仮定する。

さらに、ある波長帯域（例：C バンド）で学習したモデルは、異なる波長帯域（例：O バンド）に対しても、一定の汎用性を持って変換が可能であると考える。



電磁場画像



強度画像

図 1.4 電磁場画像（上）と対応する強度分布画像（下）の比較。両者の間には物理的な対応関係が存在し、機械学習による相互変換が可能であると仮定する。

1.4 研究目的

本研究の目的は、機械学習を用いた画像処理技術を適用し、以下の二つの技術を確立することで、PIC 設計の効率化に貢献することである。

1. シミュレーション効率化のための超解像技術の確立

粗いメッシュでの計算結果（低解像度画像）から、微細メッシュ相当の電磁界分布（高解像度画像）を再構成する CNN(Convolutional Neural Network) モデルを構築する。PSNR(Peak Signal-to-Noise Ratio) のような定量的指標を用い、計算時間の短縮が可能であることを実証する。

2. データ再利用のための画像相互変換技術の確立

電磁界分布画像と強度分布画像を相互に変換する Pix2Pix モデルを構築する。視覚的に区別不可能な水準 (PSNR 30 dB 程度) で再構成が可能であることを示し、過去の設計資産の有効活用による設計フロー効率化の可能性を提示する。

第 2 章

参考技術

2.1 時間領域有限差分法 (FDTD 法)

時間領域有限差分法 (Finite-Difference Time-Domain method: FDTD 法) は、マクスウェル方程式を空間および時間領域で差分化し、電磁界の挙動を逐次計算する手法である。

真空中のマクスウェル方程式は以下の 4 式で表される。

$$\nabla \cdot \mathbf{D} = \rho \quad (2.1)$$

$$\nabla \cdot \mathbf{B} = 0 \quad (2.2)$$

$$\nabla \times \mathbf{E} + \frac{\partial \mathbf{B}}{\partial t} = 0 \quad (2.3)$$

$$\nabla \times \mathbf{H} - \frac{\partial \mathbf{D}}{\partial t} = \mathbf{j} \quad (2.4)$$

ここで、 \mathbf{D} は電束密度、 \mathbf{E} は電界、 \mathbf{B} は磁束密度、 \mathbf{H} は磁界、 ρ は電荷密度、 \mathbf{j} は電流密度を表す。また、電束密度 \mathbf{D} と電界 \mathbf{E} 、磁束密度 \mathbf{B} と磁界 \mathbf{H} 、電流密度 \mathbf{j} と 電界 \mathbf{E} の関係は、真空中で以下のように表される。

$$\mathbf{j} = \sigma \mathbf{E} \quad (2.5)$$

$$\mathbf{D} = \epsilon_0 \mathbf{E} \quad (2.6)$$

$$\mathbf{B} = \mu_0 \mathbf{H} \quad (2.7)$$

このとき ϵ_0 は真空の誘電率、 μ_0 は真空の透磁率、 σ は導電率である。物質中では ϵ_0 の代わりに $\epsilon = \epsilon_r \epsilon_0$ が、 μ_0 の代わりに $\mu = \mu_r \mu_0$ が用いられる。ここで ϵ_r および μ_r はそれぞれ物質の比誘電率、比透磁率である。これらを式 (2.3) および式 (2.4) に代入することで、FDTD 法で直接解

くべき以下の連立偏微分方程式が得られる。

$$\varepsilon \frac{\partial \mathbf{E}}{\partial t} = \nabla \times \mathbf{H} - \sigma \mathbf{E} \quad (2.8)$$

$$\mu \frac{\partial \mathbf{H}}{\partial t} = -\nabla \times \mathbf{E} \quad (2.9)$$

FDTD 法では、Yee 格子と呼ばれるスタガード格子を用い、電界と磁界を空間的・時間的に半ステップずらして配置することで計算を行う。空間および時間の一階微分を中央差分で近似することにより、計算精度を向上させている。

例として、損失のない媒質 ($\sigma = 0$) における E_x 成分の更新式は、時間ステップ n と空間座標 (i, j, k) を用いて以下のように導出される。

$$E_x^{n+1}(i + \frac{1}{2}, j, k) = E_x^n(i + \frac{1}{2}, j, k) + \frac{\Delta t}{\varepsilon \Delta y} \left(H_z^{n+\frac{1}{2}} - H_z^{n-\frac{1}{2}} \dots \right) \quad (2.10)$$

本研究ではフリーソフト OpenFDTD[3] を使用しシミュレーションを行った。

2.2 Multi-Mode Interferometer (MMI)

光集積回路において、光の分岐・合波やスイッチングを行う重要な素子として多モード干渉計 (Multi-Mode Interferometer: MMI) がある。MMI は、多モード導波路内での高次モード間の干渉を利用して、入力光の像を特定の位置に自己結像 (Self-Imaging) させる素子である。自己結像の原理により、多モード導波路の長さや幅を適切に設計することで、1 入力 N 出力の分岐や、N 入力 M 出力の合波・分波機能を実現できる。特に、 2×2 MMI カプラは、光通信の大容量化を支えるデジタルコヒーレント通信において重要な役割を果たしている。例えば、四位相偏移変調 (Quadrature Phase Shift Keying : QPSK) 信号の復調器において、信号光と局発光を干渉させ、90 度の位相差を持つ成分を取り出すために用いられる。MMI の出力における位相バランスや分岐比は、素子の幾何学的寸法に敏感であるため、設計段階における高精度なシミュレーションが不可欠である。

2.3 置み込みニューラルネットワーク (CNN)

2.3.1 概要

置み込みニューラルネットワーク (Convolutional Neural Network: CNN) は、画像認識や画像生成の分野で成果を上げている深層学習モデルの一種である [4]。このモデルは、画像内の「局所的な相関」を効率的に抽出する能力に長けている。

従来の全結合型ニューラルネットワークでは、入力画像の全画素を独立した入力として扱うため、画素間の位置関係が無視され、パラメータ数が膨大になるという欠点があった。これに対し CNN は、後述する置み込み層とプーリング層を組み合わせることで、位置ずれに対する不变性を持ちつつ、空間的な特徴を階層的に学習することが可能である。

2.3.2 主要な構成層の役割

置み込み層 (Convolutional Layer)

置み込み層は、入力画像に対してカーネル（フィルタ）と呼ばれる小さな重み行列をスライドさせながら積和演算を行う層である。画像 I とカーネル K の演算は次のように定義される。

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n)K(m, n) \quad (2.11)$$

ここで生成される $S(i, j)$ は特徴マップと呼ばれる。カーネル内の重みは学習を通じて最適化され、初期の層ではエッジや色などの単純な特徴を、深い層ではそれらを組み合わせた複雑なパターンを抽出する。

活性化関数 (Activation Function)

置み込み層の出力には、非線形性を導入するために活性化関数が適用される。本研究では主に ReLU(Rectified Linear Unit) を用いる。

$$f(x) = \max(0, x) \quad (2.12)$$

この関数は、勾配消失問題を緩和し、ネットワークの学習を高速化・安定化させる効果がある。

プーリング層 (Pooling Layer)

プーリング層は、特徴マップの解像度を縮小し、情報の圧縮と過学習の抑制を行う層である。本研究の超解像タスク (??) では解像度維持のために省略される場合もあるが、画像相互変換 (4) のような大局的な特徴抽出が必要なタスクでは重要な役割を果たす。

2.3.3 学習プロセス

ネットワークの重み更新は、定義された損失関数（平均二乗誤差など）を最小化するように、誤差逆伝播法を用いて行われる。最適化アルゴリズムには Adam 等の勾配降下法をベースとした手法が広く用いられており、これにより画像間の複雑な非線形写像の獲得が可能となる。

2.4 超解像技術

超解像 (Super-Resolution: SR) とは、低解像度の画像から高解像度の画像を推定・生成する技術である。本研究における超解像タスクでは、粗いメッシュで計算された低解像度な電磁界分布画像を入力とし、微細なメッシュで計算された高解像度な電磁界分布画像を推定することを目指す。SRCNN (Super-Resolution CNN) [5] は、低解像度画像から高解像度画像への非線形なマッピングを学習することで、従来の補間手法（バイキューピック法など）よりも鮮明な画像を再構成することを可能にした。本研究でもこの考え方を応用し、計算コストの削減を図る。

2.5 画像相互変換技術

画像相互変換は、ある画像を別の画像へ変換する技術である。光回路シミュレーションにおいては、電磁界分布と強度分布という異なる物理量の可視化画像が存在する。これらは物理法則によつて紐づいているが、その関係は非線形である。機械学習を用いることで、この複雑な対応関係を学習し、一方の画像から他方の画像を再構成することを試みる。

2.5.1 Pix2Pix の概要と適用例

本研究では画像変換技術として、条件付き敵対的生成ネットワーク (Conditional Generative Adversarial Networks: cGAN) に基づいた画像対画像の変換モデルである Pix2Pix を採用した [6]。Pix2Pix は、一対の対応する画像データを用いて、画像間の変換則を学習する。この手法は一

一般的には以下のような様々なタスクに適用されている。

- 地図から衛星画像への変換: 記号化された道路地図から複雑な地表の航空写真を生成する
(図 2.1)
- 白黒写真的カラー化: 輝度情報のみの画像から、もっともらしい色彩を推測して付与する
- 線画から写真的生成: 簡単なスケッチから、質感を持ったリアルな物体画像を再構成する

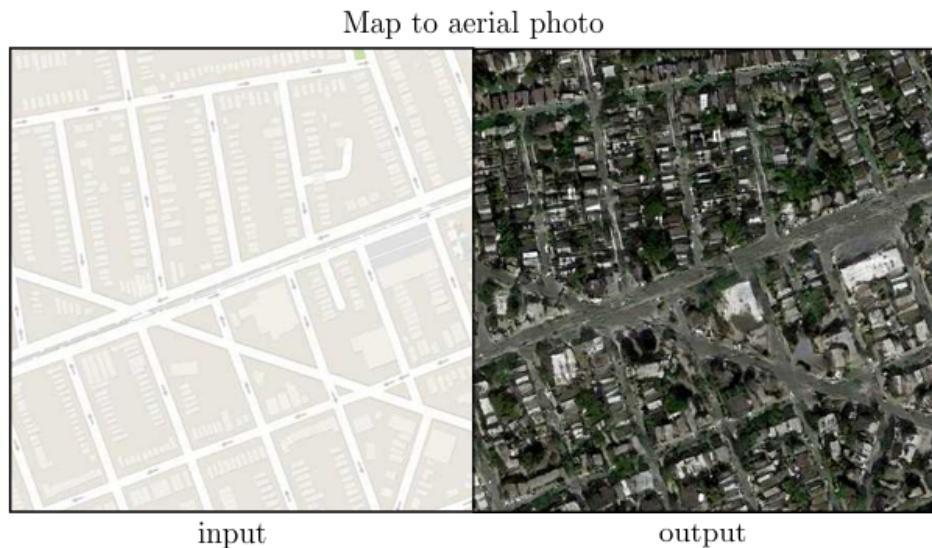


図 2.1 Pix2Pix の使用例 (地図から衛星画像への変換)[6]。

本研究では、この画像変換能力を応用し、強度分布画像から電磁界分布を再構成するタスクに適用する。

2.5.2 ネットワークの構成：U-Net と PatchGAN

Pix2Pix は、生成器 (Generator) と識別器 (Discriminator) の 2 つのネットワークで構成される。

生成器: U-Net 構造

生成器には、エンコーダ・デコーダ構造を持つ U-Net が用いられる。U-Net の特徴は、エンコーダの各層とデコーダの対応する層を直接結ぶスキップ接続である。これにより、エンコーダで抽出された低次の詳細な空間情報が圧縮によって失われるのを防ぎ、高精度な画像の生成を可能にしている。

識別器: PatchGAN

識別器には、画像を小さなパッチ単位で判定する PatchGAN が採用されている。画像全体を一つの値で判定するのではなく、局所的な領域ごとに本物らしさを評価することで、生成画像の高周波成分を向上させ、不鮮明な箇所の少ないパターンの復元を実現している。

2.5.3 学習の目的関数

Pix2Pix は、識別器を欺くように学習する敵対的損失 \mathcal{L}_{cGAN} と、生成画像が正解画像から画素レベルで乖離しないように制約する L1 損失を組み合わせて学習を行う。

$$G^* = \arg \min_G \max_D \mathcal{L}_{cGAN}(G, D) + \lambda \mathcal{L}_{L1}(G) \quad (2.13)$$

この損失関数により、物理的な構造を維持しつつ、細かな変化をリアリティを持って再現することが可能となっている。

2.6 評価指標

2.6.1 PSNR

画像の生成精度を定量的に評価する指標として、ピーク信号対雑音比 (Peak Signal-to-Noise Ratio: PSNR) を用いる。 $m \times n$ 画素の正解画像 I と生成画像 K において、平均二乗誤差 (MSE) は以下で定義される。

$$MSE = \frac{1}{mn} \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} [I(i, j) - K(i, j)]^2 \quad (2.14)$$

画像の最大輝度値を MAX_I とすると、PSNR は以下の式で表される。

$$PSNR = 10 \cdot \log_{10} \left(\frac{MAX_I^2}{MSE} \right) = 20 \cdot \log_{10} \left(\frac{MAX_I}{\sqrt{MSE}} \right) \quad (2.15)$$

一般的に、PSNR が 30 dB 以上であれば、視覚的に劣化が気にならない高品質な画像であるとされる。[7]

2.6.2 LPIPS

LPIPS(Learned Perceptual Image Patch Similarity) は、深層学習モデル (VGG や AlexNet など) の内部層から抽出された特徴マップ間の距離として画像間の類似度を定義する指標である [8]。従来の PSNR は全画素の輝度値誤差を平均するため、画像のコントラストや全体的な明るさが僅かに変化しただけでスコアが極端に悪化する傾向がある。一方、LPIPS は画像の構造的な特徴やパターンを重視するため、人間が直感的に似ていると感じる度合いをより正確に数値化できる。

評価値の解釈

LPIPS は、値が小さいほど正解に近いことを意味する。

- **0.0:** 正解と完全に同一
- **0.1 以下:** 人間の目で見ても区別が困難なほど、構造やパターンの再現性が極めて高い
- **0.3 以上:** 知覚的に明らかな構造の崩れや、物理的特徴の欠落が見られる

物理現象である電磁界分布の再構成においては、輝度の絶対値よりも干渉縞の位置や形状が重要であるため、特定の検証フェーズにおいては LPIPS による評価が極めて有効である。

2.7 光通信における波長帯

本研究では、提案手法の汎用性を検証するために、C バンドおよび O バンドという 2 つの代表的な波長帯域を用いている。光通信において、これらの波長帯は光ファイバの伝送損失や分散特性に基づいて定義されており、PIC の設計においても極めて重要である。

2.7.1 O バンド (Original Band)

O バンドは、波長 1260 nm から 1360 nm の範囲を指す。この帯域は、石英光ファイバにおいて材料分散と構造分散が打ち消し合う零分散波長近傍に位置しており、長距離伝送における信号波形の歪みが小さいという特徴を持つ。シリコンフォトニクスデバイスにおいては、シリコン導波路の透明波長領域に含まれるため、短距離・高速通信 (データセンター内通信など) をターゲットとした PIC 設計で広く利用されている [9][10]。

2.7.2 C バンド (Conventional Band)

C バンドは、波長 1530 nm から 1565 nm の範囲を指す。この帯域は石英光ファイバの伝送損失が最も低くなる帯域であり、光増幅器 (EDFA) の増幅帯域とも一致するため、基幹網や長距離通信、波長分割多重 (WDM) 通信において最も標準的に利用されている [9][10]。

第 3 章

超解像によるシミュレーションの効率化

3.1 はじめに

本章では、序論で述べた PIC 設計における計算リソースの増大という課題を解決するために、機械学習を用いた超解像技術を適用し、低解像度のシミュレーション結果から高解像度の電磁界分布を再構成する手法について述べる。また、提案手法の汎用性を検証するために、学習時と推論時で異なる波長帯域を用いた。その結果についても報告する。

なお、本章で述べる手法および検証結果の一部については、国際会議 CIF 2023、CLEO-PR 2024 にて報告を行っている [11][12]。

3.2 機械学習による超解像の原理

本節では、本研究の核となる CNN および本研究で採用した超解像アルゴリズムである SRCNN の理論的背景について、詳細に解説する。

3.2.1 CNN

CNN は全結合層とは異なり、入力データの空間的な局所性を保持したまま情報を処理できる。CNN における主要な演算である畳み込みは、入力画像 X に対して、特定の重みを持つフィルタ（カーネル） W をスライドさせながら積和演算を行う。出力される特徴マップ Y は以下の式

で表される。

$$Y = \sigma(W * X + b) \quad (3.1)$$

ここで、 $*$ は畳み込み演算、 σ は活性化関数、 b はバイアス項である。このフィルタの重みを学習によって最適化することで、画像からエッジ、テクスチャ、あるいはより抽象的な物理的特徴を抽出することが可能となる。

3.2.2 SRCNN

SRCNN は、単一画像超解像のためのエンドツーエンドな学習モデルである。従来の超解像手法が複雑な最適化問題を解く必要があったのに対し、SRCNN は以下の 3 つの畳み込み層 [5] によって、低解像度画像から高解像度画像へのマッピングをシンプルに実行する。

1. **Patch extraction and representation (パッチ抽出と表現)** : 低解像度画像から局所的なパッチを抽出し、それを高次元の特徴ベクトルとして表現する。
2. **Non-linear mapping (非線形マッピング)** : 抽出された低解像度の特徴ベクトルを、高解像度の特徴ベクトルへと非線形に写像する。
3. **Reconstruction (再構成)** : 高解像度の特徴マップを組み合わせ、最終的な高解像度画像を生成する。

従来のバイリニア補間などの幾何学的な手法が周辺画素の線形平均に基づいているのに対し、SRCNN は非線形な関係を学習するため、物理現象に特有の急峻な変化や干渉パターンを高い再現性で復元できる特長がある。

3.3 研究手順

3.3.1 シミュレーションデバイスとデータ生成

機械学習の学習データとして電磁界パターンを収集するため、光回路の FDTD シミュレーションを行った。

デバイス構造

本研究では、干渉計ベースのシンプルな構造を採用した。具体的には、 2×2 MMI から 1 つの入力導波路と 2 つの出力導波路を取り外したデバイスを使用する。(図 3.1)。この構造を用いること

で、機械学習の学習素材となる電磁界パターンの画像を取得している。

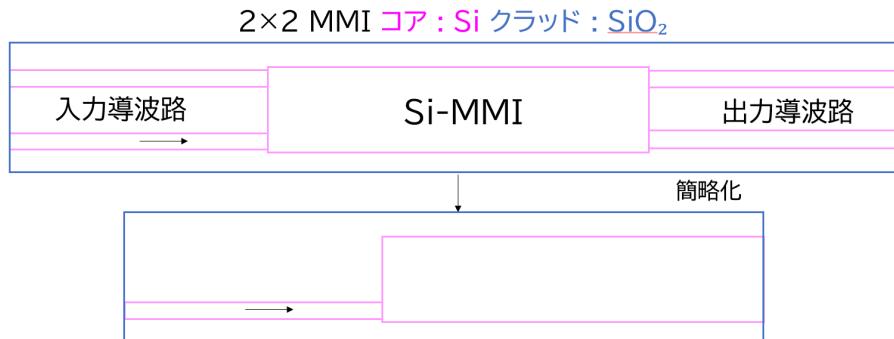


図 3.1 本研究で使用した学習データ生成用のデバイス。

計算条件とメッシュサイズ

シミュレーションには 3 次元 FDTD 法を用いた。以下のメッシュサイズを設定した。

- **20 nm メッシュ**: 高解像度 (High-Resolution: HR)。教師データとして使用。
- **40 nm メッシュ**: 低解像度 (Low-Resolution: LR)。入力データとして使用。

メッシュサイズを細かくするほど計算時間は指数関数的に増大する。20 nm メッシュでの計算と比較して、40 nm メッシュでは計算時間を短縮できるため、この低解像度画像から高解像度画像を復元できれば設計効率は大きく向上する。

3.3.2 SRCNN モデルと学習プロセス

SRCNN は、低解像度画像と高解像度画像のペアを学習させることで、画像の特徴量を抽出し、低解像度画像から高解像度画像を再構成する。本節では、学習に使用したデータセットの構築方法、SRCNN モデルの構造および学習に使用したハイパーパラメータについて述べる。

データセットの構築

シミュレーションで得られた電磁界分布画像を、それぞれ 20 枚の画像に分割した。分割された画像のうち、電磁界がほとんど存在しない部分は、学習データとして無意味でありノイズとなる可能性があるため除外した。残った画像ペアを以下のグループに分割した（図 3.2）。

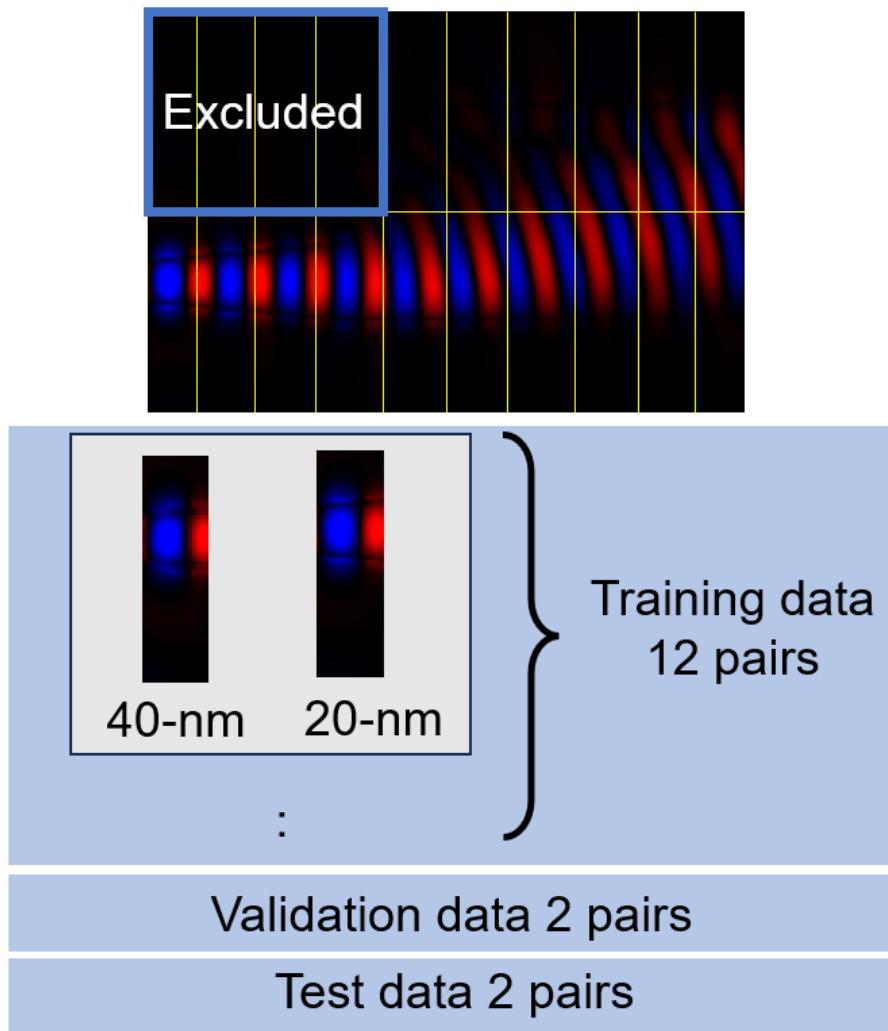


図 3.2 SRCNN の学習に使用したデータセット。

ネットワーク構造とパラメータ

構築した SRCNN モデルの構造およびハイパーパラメータは以下の通りである。

- **第 1 層 (畳み込み層)** : フィルタ数 16, フィルタサイズ 3×3 , 活性化関数 ReLU
- **第 2 層 (畳み込み層)** : フィルタ数 3, フィルタサイズ 3×3 , 活性化関数 ReLU
- **最適化手法**: Adam
- **損失関数**: 平均二乗誤差 (MSE)
- **評価指標**: PSNR
- **エポック数**: 15000

- バッチサイズ: 32

3.3.3 検証手順

提案手法の性能と適用範囲を示す目的で、以下の 3 つの検証を進める。

1. 一般画像による学習モデルでシミュレーション画像を超解像

SRCNN が特定の物理データに依存せず、画像としての基本的な復元能力を有するかを検証するため、図 3.3 に示したような一般画像が含まれ、Kaggle で公開されているデータセット General100[13] を学習データとして用い、シミュレーション画像を超解像する。



図 3.3 General100 に含まれる画像の例。LR の画像は HR の画像を縮小することによって作成した。

2. 学習時と同じ波長帯のシミュレーション画像を超解像

C バンド (波長 1550nm 帯) のシミュレーション結果を学習データとして用い、同帯域のシミュレーション画像を超解像する。

3. 学習時とは異なる波長帯のシミュレーション画像を超解像

C バンドのデータで学習したモデルを用いて、異なる波長帯域である O バンド (波長 1300 nm 帯) のシミュレーション画像の超解像を超解像する。学習時とは異なる条件下でのモデルの汎用性を検証する。

また、比較対象として、従来の画像補間手法であるバイリニア補間 (Bilinear interpolation) およびバイキュービック補間 (Bicubic interpolation) による結果と比較する。

3.4 結果

3.4.1 一般画像学習モデルの結果

一般画像(図3.3)で学習したモデルをシミュレーション画像の超解像に適用した結果、PSNRの改善幅は約1dBに留まった図(3.4)。これは、一般画像の学習によってある程度の超解像能力が確保されたものの、電磁界分布特有の周期的なパターンを補完するための知識が不足していたためと考えられる。

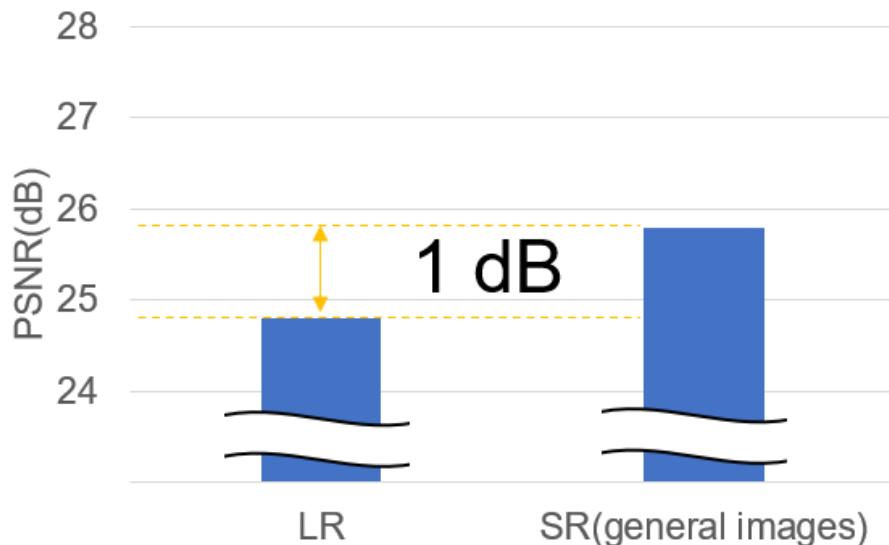


図3.4 一般画像を学習したモデルを用いてシミュレーション画像を超解像した結果。

3.4.2 Cバンド学習モデルの評価

Cバンドのシミュレーション画像を学習データとして用いたモデルを評価した。結果として、PSNRは大幅に向上し、約8dBの改善が見られた(図3.5)。再構成された画像のPSNRは30dBを超えており、視覚的にも高解像度画像と遜色のないレベルまで品質が向上した。これにより、SRCNNの高い再構成能力が確認された。

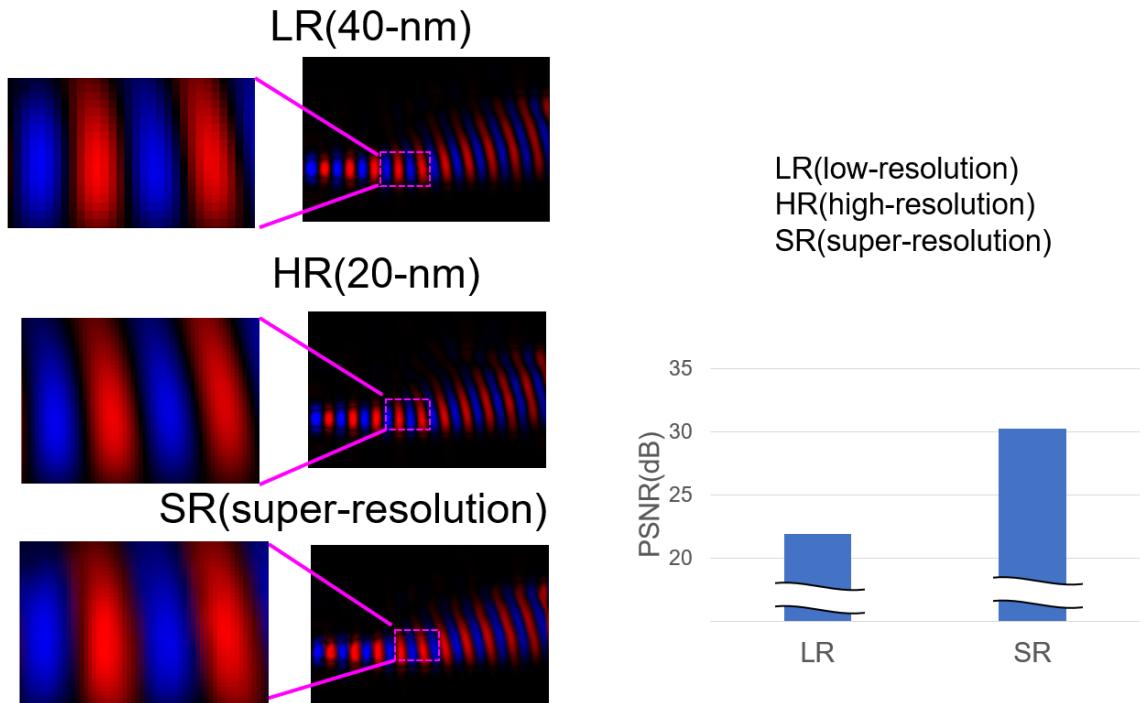


図 3.5 C バンドを学習したモデルを用いて C バンド画像を超解像した結果。

3.4.3 異波長 (O バンド) への適用結果

C バンドのデータで学習したモデルを用いて、O バンドのシミュレーション画像を超解像した。結果として、C バンドでの推論時と同等の約 30 db の PSNR 値が得られた (図 3.6)。波長が異なっても、光の干渉や伝搬といった物理現象に由来する画像の特徴は共通しているため、モデルがその特徴を捉えて汎化できたと考えられる。この結果は、一度モデルを構築すれば、異なる波長条件のシミュレーションに対しても再学習なしで適用できる可能性を示している。

3.4.4 従来手法との比較

SRCNN による超解像と、従来の補間手法 (バイリニア、バイキュービック) による結果を比較した。図 3.7 に示すように、従来手法もある程度の画質改善効果はあるものの、SRCNN と比較するとその効果は約 1 dB 程度と小さい。SRCNN は、学習データから画像の特徴を学習することで、単なる幾何学的な補間よりも高度な高解像度化を実現していると言える。

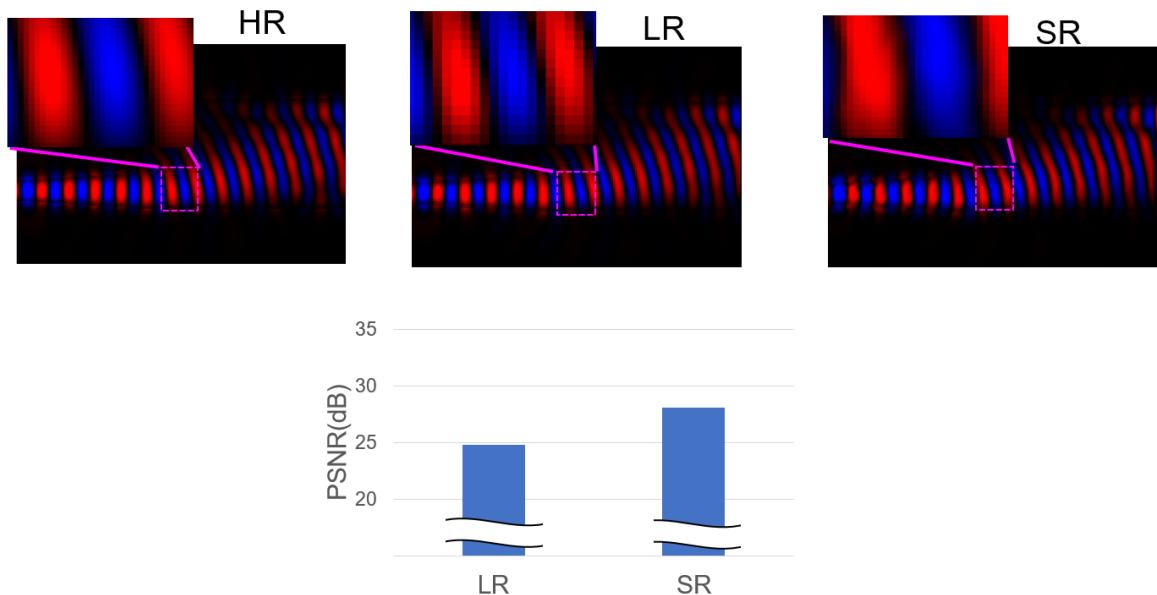


図 3.6 C バンドを学習したモデルを用いて O バンド画像の超解像を行った結果。

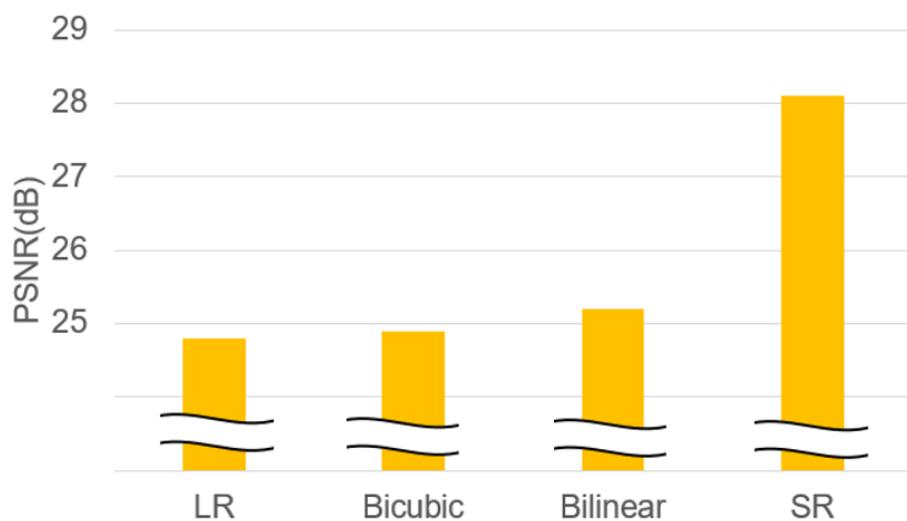


図 3.7 SRCNN と従来の補間手法 (バイリニア, バイキューピック) による PSNR の比較。

3.5 まとめ

本章では、PIC 設計における計算リソース削減を目的として、SRCNN を用いたシミュレーション画像の超解像手法を提案・検証した。検証の結果、SRCNN は従来の補間手法よりも優れた再構

成能力を示した。一般画像による学習では限界があるものの、学習時と同じ波長帯のものを超解像したとき、PSNR30dB を超える高精度な画像再構成が可能であることを確認した。さらに、C バンドで学習したモデルが O バンドのシミュレーション画像に対しても有効であることが示され、提案手法の汎用性が実証された。これらの結果は、SRCNN が将来の大規模かつ複雑な PIC 設計において、計算コストを削減するための重要な技術となり得ることを示している。

第 4 章

画像相互変換による設計資産の活用

4.1 はじめに

PIC の設計プロセスにおいて、電磁界シミュレーションはデバイス特性を予測するために不可欠である。通常、設計者はシミュレーションを通じて位相差、分岐比などの値を確認する。しかし、これらの値を算出するための元データとなる詳細な 3 次元電磁界分布データ ($E_x, E_y, E_z, H_x, H_y, H_z$ の 6 成分) は、データ容量が極めて大きいため、ストレージ容量の制約から、設計パラメータが確定した後には破棄されることが一般的である。

一方で、シミュレーション結果の確認や、論文・報告書への掲載のために生成された可視化画像(電磁界分布画像や強度分布画像)は、比較的軽量に保存されており、設計者の手元に蓄積されている場合が多い。これらの画像データは数値データそのものではないが、デバイス内の光の振る舞いに関する重要な情報を含んでいる。

本章では、これらの蓄積された画像データを設計資産として再利用し、新たなシミュレーションを行うことなく必要な物理情報を復元する手法について述べる。具体的には、機械学習を用いて、電磁界分布画像と強度分布画像の相互変換を試みる。

4.2 電磁界分布画像から強度分布画像への変換

まず、第一段階として、情報量の多い電磁界分布画像から、情報量の少ない強度分布画像を再構成する手法について述べる。電磁界分布画像には位相情報が含まれているため、強度への変換は比較的容易であると予想される。本研究では、この変換プロセスに CNN を適用し、その有効性について CIF 2025 にて報告した内容に基づき詳述する [14]。

4.2.1 研究手順

シミュレーションデバイスとデータセットの生成

学習データおよびテストデータを生成するために、シミュレーションを行った。

対象デバイスとして、Si コアと SiO_2 クラッドからなる 2×2 MMI を採用した。汎用性を検証するため、以下の 2 つの異なる波長帯域 (C バンドおよび O バンド) で設計されたデバイスを用意した (図 4.1)。

- **C バンド用デバイス:** 入力ポート幅 : 440 nm 高さ : 220 nm MMI 領域のサイズ : $2.21 \mu\text{m} \times 16.5 \mu\text{m}$ 。
- **O バンド用デバイス:** 入力ポート幅 : 370 nm 高さ : 220 nm MMI 領域のサイズ : $1.98 \mu\text{m} \times 17.5 \mu\text{m}$ 。

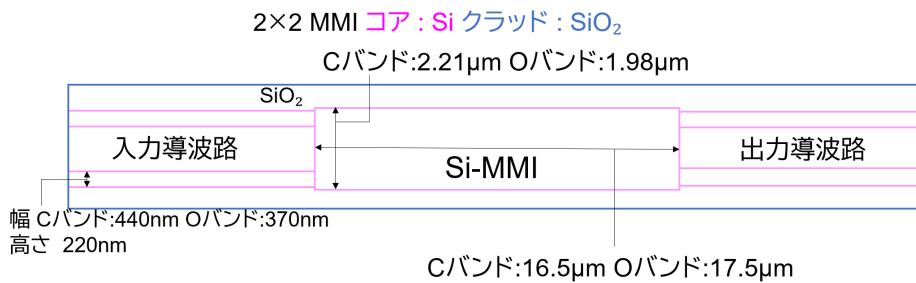


図 4.1 本研究で使用した学習データ生成用の C バンド、O バンドのデバイス。

本研究の目的は干渉パターンの変換則を学習することにあるため、データセットの生成においては、 2×2 MMI の干渉計の箇所のみを画像として切り出して使用した (図 4.2)。

可視化カラーマップの多様性

設計現場において蓄積される画像資産は、シミュレーションソフトの設定や報告書の意図に応じて、多様なカラーマップで可視化されている場合がある。提案手法が設計資産の再利用に貢献するためには、これらの表示形式の違いに依存せず、一貫して強度分布を推定できる能力が求められる。そこで本研究では、单一の表示形式だけでなく、複数の異なるカラーマップで描画された電磁界分布画像を用意し、それらを入力とした際の変換精度を個別に検証した。図 4.2 に示したカラーマップの他に、図 4.3 に示したカラーマップの電磁界分布画像を用意した。

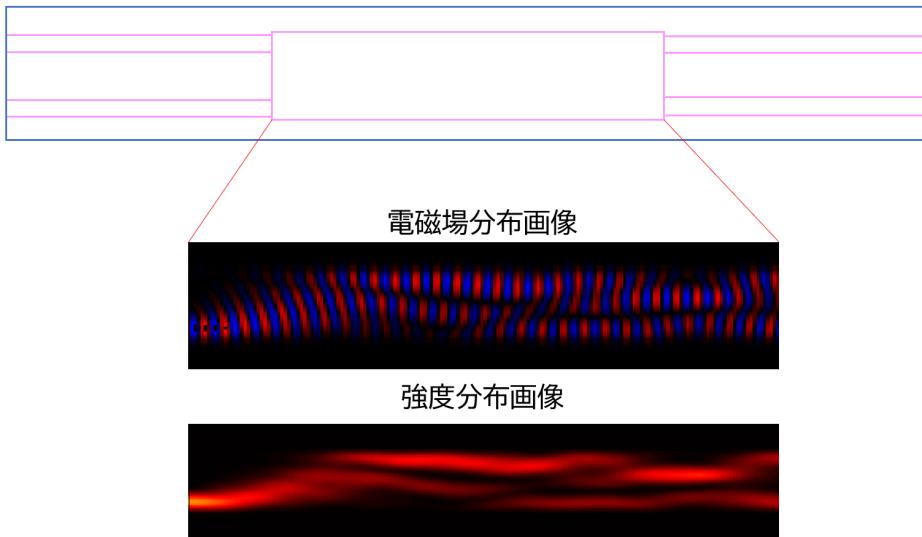


図 4.2 電磁界分布画像と強度分布画像は干渉計の箇所を切り出して使用する。

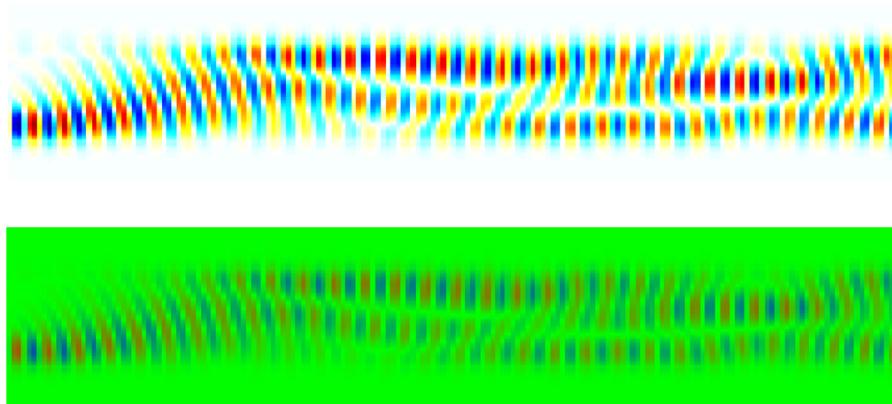


図 4.3 他のカラーマップの電磁界分布画像。

CNN モデルの学習

電磁界分布画像を入力とし、強度分布画像を出力とする CNN モデルを構築した。

■データセットの構築 生成された電磁界分布画像とそれに対応する強度分布画像のペアに対し、前処理を行った。それぞれの画像を 20 個のセグメントに分割し、これらのペアをそれぞれのカラーマップごとに学習データとして使用した(図 4.4)。

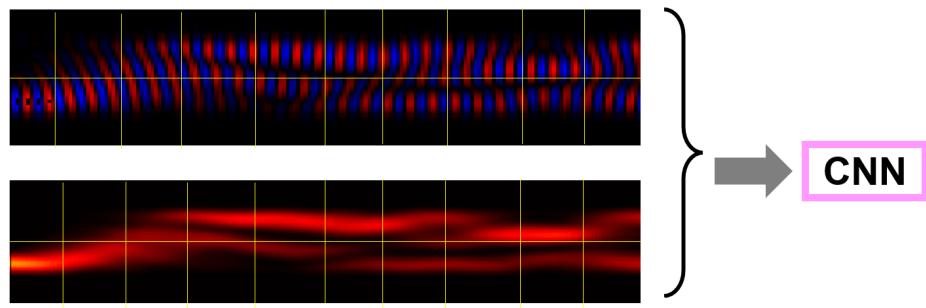


図 4.4 CNN の学習に使用したデータセット。

■ネットワーク構造 モデル構造として、3層の畠み込み層からなる CNN を採用した。ネットワークの具体的な構成および学習に使用したハイパーパラメータは以下の通りである。学習には、C バンドのシミュレーションで得られた画像ペアのみを使用した。

- 第 1 層:

- 入力チャンネル数: 3
- 出力チャンネル数 (フィルタ数) : 64
- カーネルサイズ: 3×3
- パディング: 1
- 活性化関数: ReLU

- 第 2 層:

- 入力チャンネル数: 64
- 出力チャンネル数 (フィルタ数) : 64
- カーネルサイズ: 3×3
- パディング: 1
- 活性化関数: ReLU

- 第 3 層:

- 入力チャンネル数: 64
- 出力チャンネル数 (フィルタ数) : 3
- カーネルサイズ: 3×3
- パディング: 1

- 学習パラメータ:

- 最適化手法: Adam
- 損失関数: 平均二乗誤差 (MSE)
- 学習率: 1×10^{-4}
- エポック数: 5000
- バッチサイズ: 4

検証手順

提案手法の汎用性を検証するため、学習完了後のモデルを用いて以下の 2 通りを推論した。

1. **C バンド推論:** 学習データと同じ C バンドの電磁界分布画像を入力とする。モデルが学習データを適切に学習できたかを確認するものである。
2. **O バンド推論:** 学習データには含まれない O バンドの電磁界分布画像を入力とする。学習時とは異なる波長に対してもモデルが適用可能かを検証するものである。

4.2.2 結果

画像再構成の結果

図 4.5、図 4.6、図 4.7、図 4.8、図 4.9、図 4.10 に、電磁界分布画像から再構成された強度分布画像の結果を示す。図 4.5、図 4.6、図 4.7 が C バンド (学習済み波長)、図 4.8、図 4.9、図 4.10 が O バンド (未知の波長) の結果である。いずれの場合も、電磁界分布画像から生成された再構成強度分布画像は、中央の正解画像と視覚的におおむね一致している。学習に使用していない O バンドのデータに対しても、入力された電磁界の干渉パターンから強度分布を生成できており、モデルが波長に依存しない対応関係を学習していることが示唆された。

定量評価 (PSNR)

再構成精度の定量的な評価として、PSNR を算出した。結果を図 4.11 に示す。

C バンドでの推論結果は 30 dB を超える高い値を示し、O バンドでの推論結果においても約 30 dB という値を達成した。この結果は、ある波長帯域で構築した変換モデルが、設計変更によって波長が変わったとしても、再学習なしで一定の精度で適用可能であることを示している。

異なるカラーマップを用いて可視化された電磁界画像に対する PSNR 評価の結果、いずれのカラーマップにおいても PSNR 30 dB 程度の高精度な再構成が可能であることを確認した。異なる

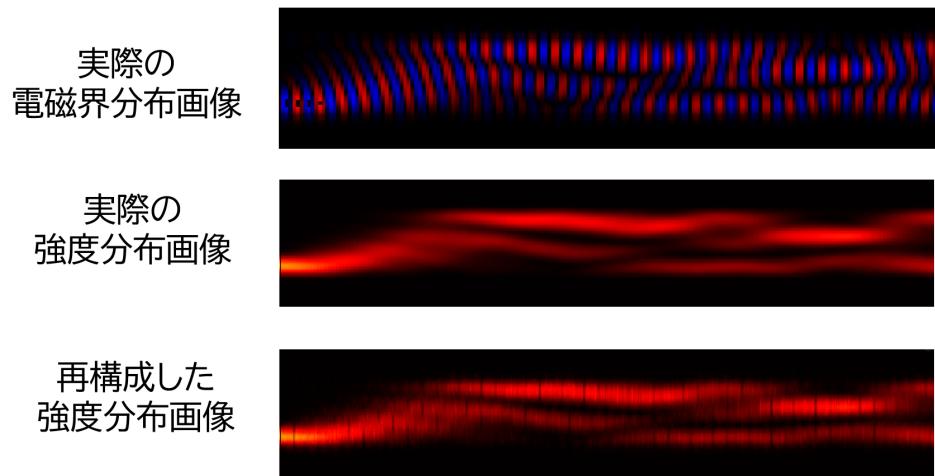


図 4.5 CNN による C バンド強度分布画像の再構成結果 (カラーマップ 1)。

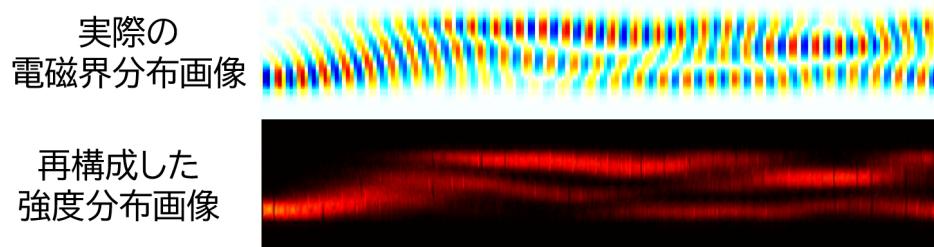


図 4.6 CNN による C バンド強度分布画像の再構成結果 (カラーマップ 2)。

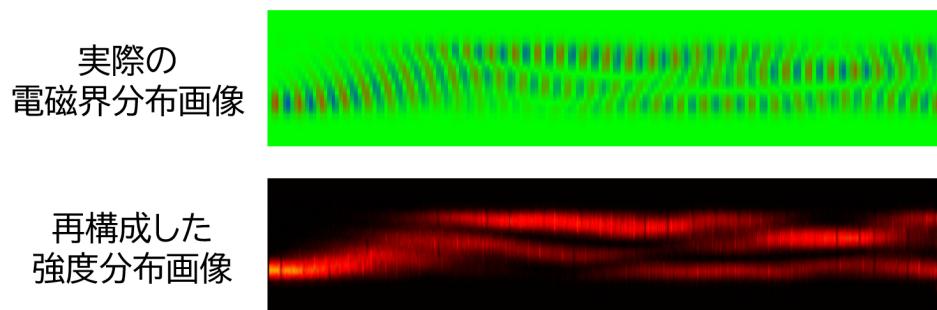
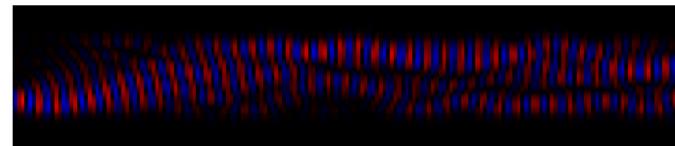
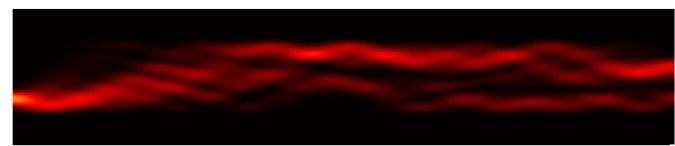


図 4.7 CNN による C バンド強度分布画像の再構成結果 (カラーマップ 3)。

実際の
電磁界分布画像



実際の
強度分布画像



再構成した
強度分布画像

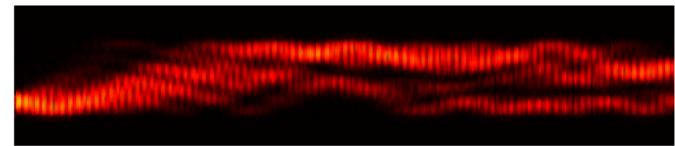
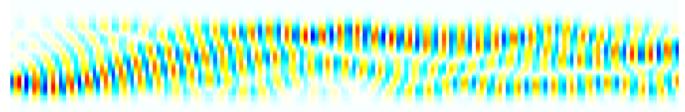


図 4.8 CNN による O バンド強度分布画像の再構成結果 (カラーマップ 1)。

実際の
電磁界分布画像



再構成した
強度分布画像

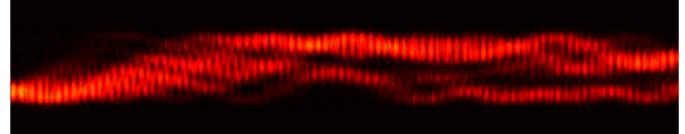
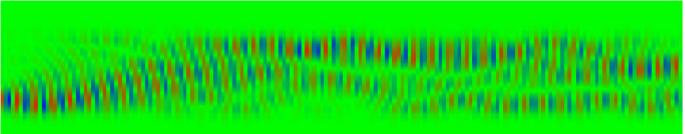


図 4.9 CNN による O バンド強度分布画像の再構成結果 (カラーマップ 2)。

実際の
電磁界分布画像



再構成した
強度分布画像

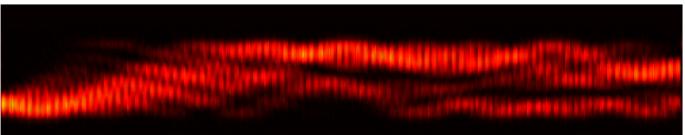


図 4.10 CNN による O バンド強度分布画像の再構成結果 (カラーマップ 3)。

色の割り当て規則を持つ入力に対しても、適切な学習ペアを与えることで、モデルは色情報を解釈し、強度分布へと再構成できることが実証された。

これらの結果から、多様の波長帯、カラーマップの過去の設計資産を活用できる可能性が示された。

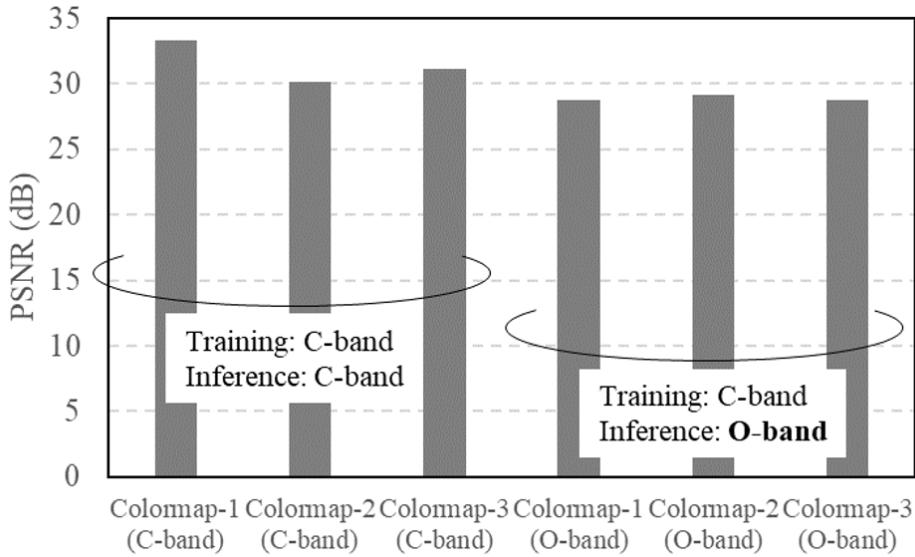


図 4.11 再構成された強度分布画像の PSNR 評価結果。C バンド (学習済み) と O バンド (未学習) の双方が 30 dB 付近の高い精度を示している。

4.3 強度分布画像から電磁界分布画像への変換

次に、逆方向の変換、すなわち強度分布画像から電磁界分布画像への再構成について検討する。

4.3.1 逆変換の困難性

「電磁界 → 強度」の変換と比較して、「強度 → 電磁界」の変換は格段に難易度が高い。これは、強度分布画像になった時点での位相情報が欠落しているためである。

本研究ではまず、前節で用いた標準的な CNN 構造を用いて強度から電磁界への逆変換を試行した。しかし、図 4.12 に示すように、生成された画像は全体的に不鮮明で、電磁界分布において物理的に重要な鮮明な干渉縞が消失するという結果となった。これは、MSE を損失関数とした学習において、不確定な位相の候補が平均化されることで、高周波成分である縞模様が平滑化されてしまう CNN の限界を示している。この課題を克服するため、本研究では生成対抗ネットワーク

(GAN) の一種である Pix2Pix を採用する。

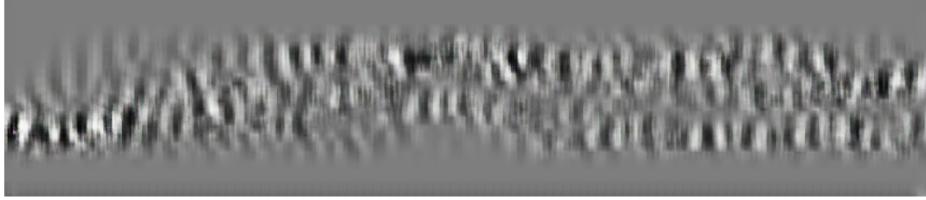


図 4.12 CNN による電磁場画像の再構成失敗例。

4.3.2 Pix2Pix による画像変換の原理

Pix2Pix は、cGAN を用いた画像変換フレームワークである。

cGAN の目的関数

cGAN では、入力画像 x (ここでは強度分布画像) を条件として、偽の画像を生成する生成器 G と、入力 x とターゲット y のペアが本物か偽物かを判定する識別器 D が対抗的に学習を行う。その目的関数 $\mathcal{L}_{cGAN}(G, D)$ は次式で表される。

$$\mathcal{L}_{cGAN}(G, D) = \mathbb{E}_{x,y}[\log D(x, y)] + \mathbb{E}_{x,z}[\log(1 - D(x, G(x, z)))] \quad (4.1)$$

ここで z はノイズである。Pix2Pix の特徴は、この敵対的損失に加え、生成画像が正解画像から大きく乖離することを防ぐための L1 損失を導入している点にある。

$$\mathcal{L}_{L1}(G) = \mathbb{E}_{x,y,z}[\|y - G(x, z)\|_1] \quad (4.2)$$

最終的な学習目標は、これらを組み合わせた次式の最適化となる。

$$G^* = \arg \min_G \max_D \mathcal{L}_{cGAN}(G, D) + \lambda \mathcal{L}_{L1}(G) \quad (4.3)$$

敵対的損失が高周波成分を、L1 損失が低周波成分を担うことで、物理的に整合性の取れた鮮明な電磁界分布の復元が可能となる。

4.3.3 研究手順

データセットの生成と構造バリエーション

本タスクでは、デバイス構造、波長、励振点の組み合わせによる多様な干渉パターンを学習させるため、複数のデータセットを作成した。学習に用いる各データには、物理条件を識別するための「ラベル情報」を付与した。なお、本解析では、学習の効率化を目的として、すべての電磁界分布画像、強度分布画像、をグレースケールとして処理した。赤と青のカラーマップによる可視化は視覚的には理解しやすいが、物理的な本質は振幅の正負や強度であり、グレースケールのみで物理現象の表現として十分である。

- 構造バリエーション（CAD パターン）：

- パターン 1: 4.2 でも使用した C バンド用 MMI デバイス
- パターン 2: 干渉計の縦幅を変更したモデル ($2.25 \mu\text{m}$)
- パターン 3: 干渉計の横幅を変更したモデル ($18.5 \mu\text{m}$)

- 波長割り当てルール（ラベル 1）：全帯域 1530–1565 nm において、以下の規則に従い波長を各構造に割り当て、これを入力ラベルとしてネットワークに与えた。

- $\lambda = 1530, 1533, 1536, \dots \text{nm}$ (パターン 1 に適用)
- $\lambda = 1531, 1534, 1537, \dots \text{nm}$ (パターン 2 に適用)
- $\lambda = 1532, 1535, 1538, \dots \text{nm}$ (パターン 3 に適用)

- 励振位置の設定（ラベル 2）：入力導波路の左端からの距離として、 $1 \mu\text{m}, 4 \mu\text{m}, 7 \mu\text{m}$ の 3 パターンの励振点を設定し、これも入力ラベルとした。

本手法では、入力として強度分布画像に加え、コア・クラッドの境目を明示した CAD 画像を同時に入力することで、モデルが構造境界を認識し、適切な位相分布を再構成できるようにしている。さらに、波長および励振点の数値を全画素に一定値として割り当てた 2 チャンネルのマップとして入力する。これにより、強度の流れだけでは決定できない位相をモデルに推論させる。また、提案手法の妥当性を検証するため、入力の強度分布画像を除外し、CAD 画像とラベルのみから電磁界分布を推論する比較実験を行った。

モデルの汎用性を検証するため、1550nm, 1551nm, 1552nm の 3 つのデータについては学習から除外し、未知の波長に対する推論用データとして確保した。

学習データの一例を図 4.13 に示す。これらは波長 1530nm、励振位置 $1 \mu\text{m}$ の条件で得られた

画像群である。

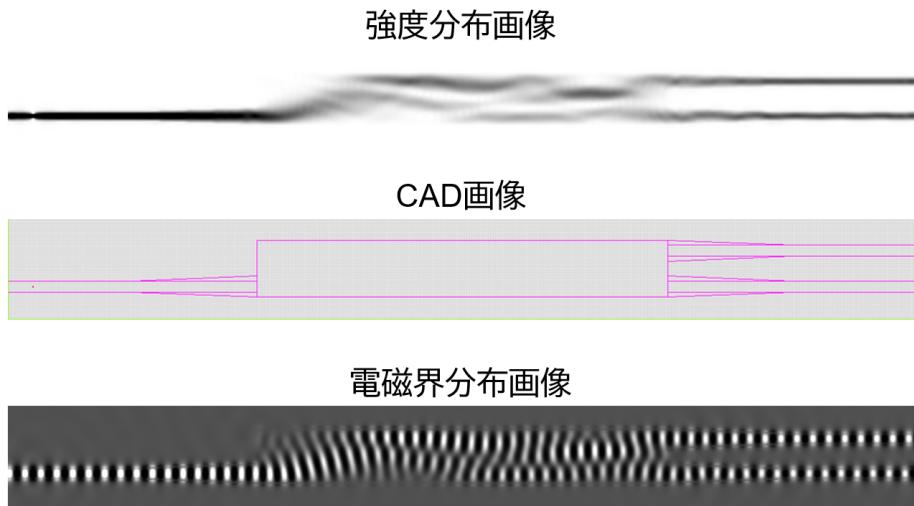


図 4.13 Pix2Pix に使用したデータセットの構成例 (波長 1530nm, 励振位置 1 μm , パターン 1)。

Pix2Pix モデルの構築

本研究では、U-Net ベースの Generator と、PatchGAN ベースの Discriminator を構築した。各ネットワークの詳細は以下の通りである。

■Generator の構成

- 構造: U-Net(エンコーダ・デコーダ構造)
- 入力層: 8 チャンネル
 - 強度分布画像 (3ch)
 - CAD 構造画像 (3ch) : コアとクラッドの境界情報の保持
 - 波長ラベル (1ch) : 全画素に正規化した波長値を割り当てたマップ
 - 励振位置ラベル (1ch) : 全画素に正規化した励振位置を割り当てたマップ
- ダウンサンプリング層: 7 層
- 正規化・ドロップアウト: InstanceNormalization を採用。中間層において Dropout (0.5) を適用し過学習を抑制。

■Discriminator の構成

- 構造: 70x70 PatchGAN

- 入力層: 11 チャンネル
 - Generator への入力 (8ch)
 - 生成画像または正解画像 (3ch)

学習条件の詳細

モデルの学習に使用したハイパーパラメータおよび条件は以下の通りである。

- 最適化手法: Adam ($\beta_1 = 0.5, \beta_2 = 0.999$)
- 学習率: 2×10^{-4}
- 損失関数:
 - 敵対的損失 (GAN Loss)
 - L1 損失 ($\lambda_{L1} = 100.0$)
- エポック数: 1,000
- バッチサイズ: 4

4.3.4 結果

強度画像を入力に含んだ場合の学習済みモデルを用いた電磁界分布画像の再構成結果を図 4.14、図 4.15、図 4.16 に示す。入力データである強度分布からは位相情報は読み取れないが、Pix2Pix によって生成された電磁界分布では、正解データと極めて近い位置に干渉縞が鮮明に復元されていることがわかる。CAD 画像によってコアとクラッドの境界情報が与えられているため、導波路構造に沿った分布が再構成されている。

定量評価として、テストデータに対する PSNR を図 4.17、図 4.18 に示す。検証の結果、注目すべき点として、強度画像を入力に含まない場合であっても、PSNR が 30 dB に達するケースが確認された。これは、提案モデルが単に入力画像のピクセル値を変換しているのではなく、CAD と波長・励振点の組み合わせから、デバイス内部で発生すべき物理的な干渉パターンの型を学習できていることを意味する。つまり、構造情報と物理ラベルのみからでも、電磁界の分布を一定の精度で予測できるポテンシャルをモデルが備えていることが示された。

一方で、強度分布画像を追加することで PSNR はさらに向上し、より安定して高精度な復元が可能となる。この結果は、CAD 画像とラベルが物理的な枠組みを定義し、強度分布画像が個別の構造における具体的な電磁界の振る舞いを補完するという、8 チャンネル入力構成の合理性を裏付

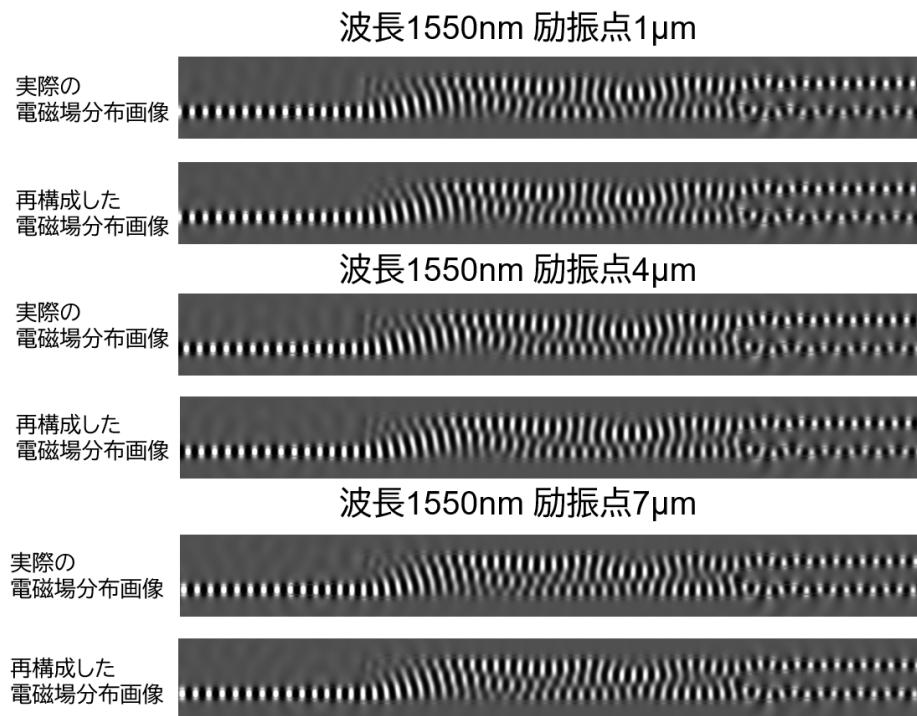


図 4.14 Pix2Pix による強度分布画像からの電磁界分布の再構成結果 (波長 1550nm)。

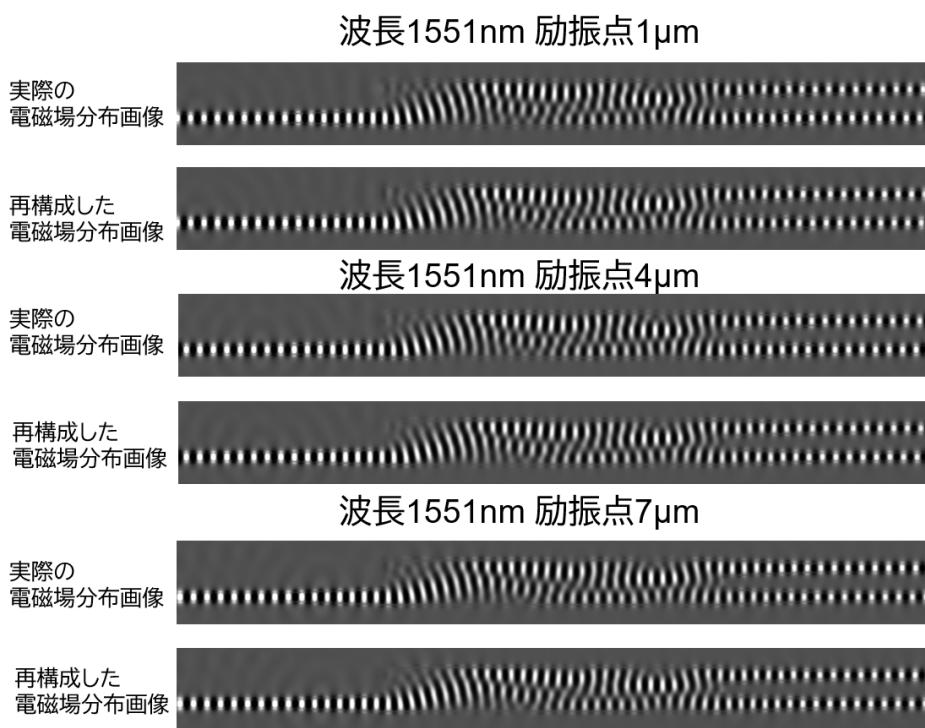


図 4.15 Pix2Pix による強度分布画像からの電磁界分布の再構成結果 (波長 1551nm)。

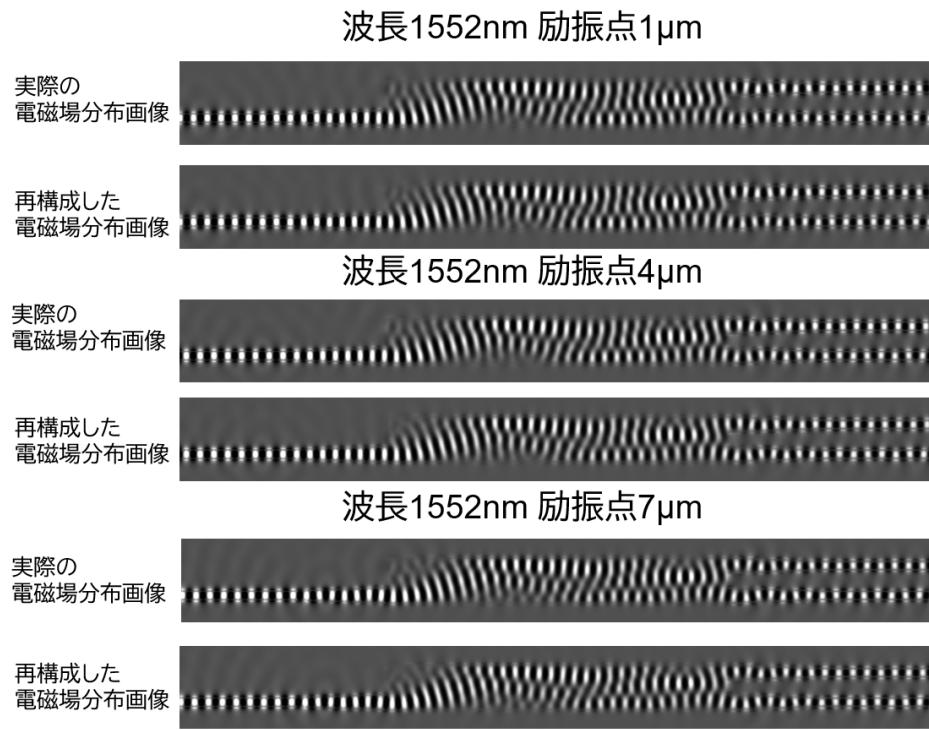


図 4.16 Pix2Pix による強度分布画像からの電磁界分布の再構成結果 (波長 1552nm)。

けるものである。これは、モデルが特定の画像を記憶するのではなく、波長や構造と電磁界の間の物理的な対応関係を学習できていることを示唆している。

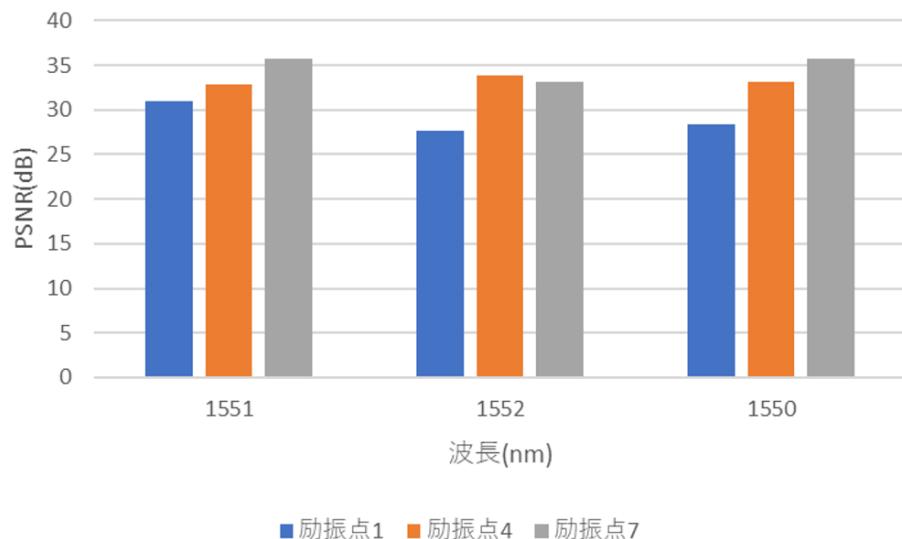


図 4.17 テストデータ (波長 1550nm, 1551nm, 1552nm) に対する PSNR 評価結果。

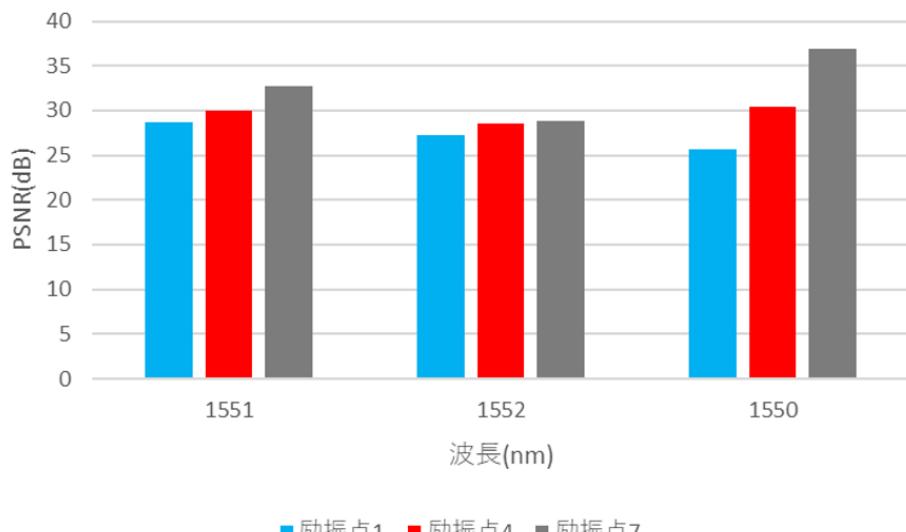


図 4.18 テストデータ (波長 1550nm, 1551nm, 1552nm) に対する PSNR 評価結果 (入力に強度分布画像無し)。

4.3.5 未知のデバイス構造に対する汎用性検証：LPIPS による評価

本章の締めくくりとして、学習データに一切含まれていなかった未知の形状を持つデバイスに対する推論実験をした。

■検証条件 対象とした構造は、干渉計が縦 $2.25 \mu\text{m} \times$ 横 $18.5 \mu\text{m}$ の MMI である。学習データには「縦 $2.25 \mu\text{m}$ (パターン 2)」や「横 $18.5 \mu\text{m}$ (パターン 3)」のバリエーションは含まれていたが、この寸法は初見となる。このデバイスに対し、波長 1530 nm、励振点 1, 4, 7 μm の条件で推論を行った。

本検証では、デバイス形状の変化に伴うコントラストや輝度の変動に左右されず、物理パターンの構造的類似性を正しく評価するため、評価指標として 2.6.2 で詳述した LPIPS を採用する。

■結果 図 4.19 に、正解データと推論結果の比較を示す。導波路境界における電磁界の閉じ込めや、多モード干渉特有の複雑な波面が鮮明に再現されていることがわかる。定量評価の結果を図 4.20 に示す。検証の結果、未学習のデバイスに対しても LPIPS は 0.1 以下を記録しており、知覚的に極めて類似した干渉縞が生成されていることが確認された。学習データにない形状に対しても LPIPS 0.1 以下という再現性を維持している点は、本手法が未知の設計パラメータに対しても機能する汎用性を備えていることを実証している。

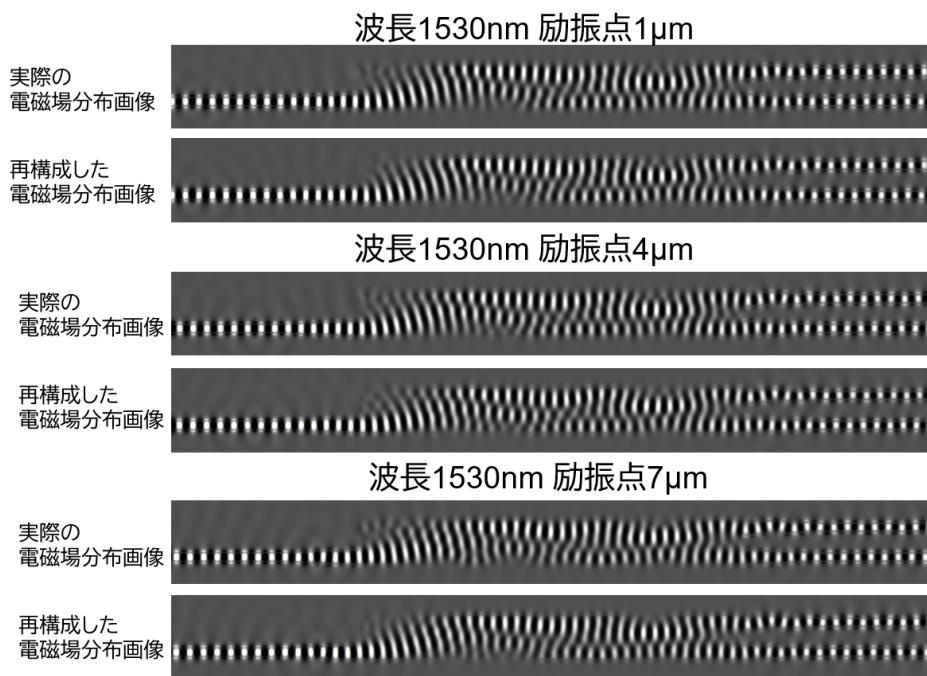


図 4.19 未知の構造における電磁界分布画像の再構成結果。

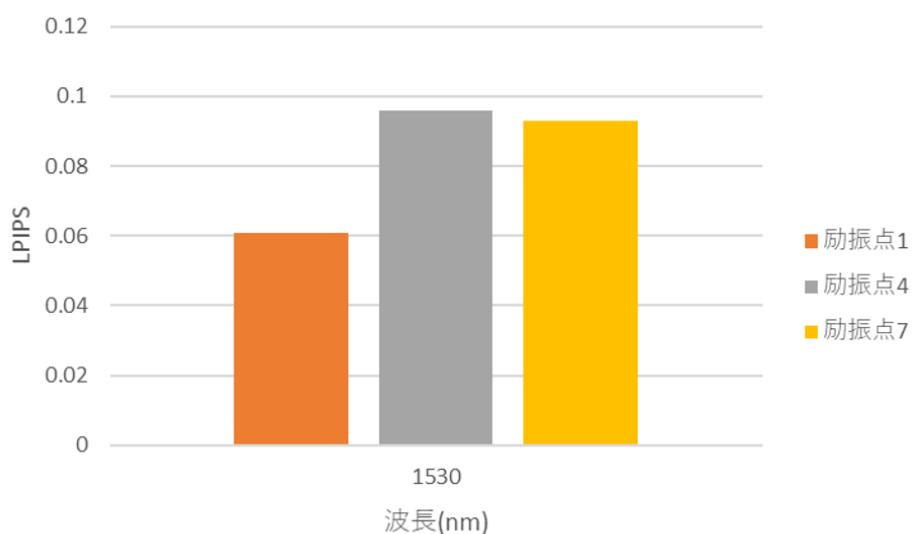


図 4.20 未知の構造における再構成電磁界分布画像に対する LPIPS 評価結果。

4.4 まとめ

本章では、数値シミュレーションデータの廃棄後に残存する画像資産を再利用するための画像相互変換技術について検討した。電磁界から強度への順変換だけでなく、困難な強度から電磁界への逆変換を Pix2Pix によって実現した。特に、CAD 画像による構造境界の制約と、波長・励振点ラベルによる物理条件をネットワークに統合して入力する手法を提案した。検証の結果、強度分布から電磁界分布画像への変換は CNN によってカラーマップに依存せず実現でき、逆変換は Pix2Pix に物理的補助情報を統合することで、PSNR 約 30 dB での復元が可能であることを実証した。強度分布画像がない場合でも物理則に基づいた予測が可能であるという知見が得られ、学習時に存在しない未知のデバイス形状に対する検証においては、LPIPS において極めて優れた値を記録し、モデルが物理則を高度に学習できていることが確認された。これらにより機械学習による PIC 設計支援の新たな可能性が示された。

第 5 章

結論

5.1 本研究の総括

本研究では、大規模化・複雑化する PIC の設計プロセスにおける計算リソースの圧迫という課題に対し、機械学習を用いた画像処理技術を適用することで、設計効率の向上を試みた。具体的には、「低解像のシミュレーション結果から高解像のシミュレーション結果を再構成」と「過去の画像資産の有効活用」という 2 つのアプローチから検討を行い、以下の成果を得た。

5.1.1 超解像技術によるシミュレーションの効率化

第 3 章では、SRCNN を用いて、粗いメッシュによる高速な FDTD シミュレーション結果(低解像度画像)から、微細なメッシュ相当の電磁界分布(高解像度画像)を推定する手法を確立した。検証の結果、提案モデルは従来の補間手法(バイリニア、バイキュービック)を大きく上回る再構成精度を示し、PSNR30dB を超える高品質な画像を生成可能であることを確認した。さらに、C バンドのデータで学習したモデルが O バンドの未知の波長帯に対しても有効に機能することを実証し、一度学習したモデルが幅広い設計条件下で汎用的に利用できる可能性を示した。これにより、低解像の結果から高解像の結果を得て計算リソースを節約できる見通しを得た。

5.1.2 画像相互変換による設計資産の再利用

第 4 章では、数値データ破棄後も残存しやすい可視化画像に着目し、CNN および Pix2Pix を用いた画像相互変換技術を開発した。まず、電磁界分布画像から強度分布画像への変換において、CNN が高い精度で物理的な対応関係を学習できることを示した。次に、位相情報が欠落している

強度画像から電磁界分布を復元するという困難な逆問題に対し、CAD 画像（コア・クラッドの境界情報）および波長・励振点のラベルを補助入力とするマルチ入力型 Pix2Pix モデルを提案した。この手法により、学習から除外した未知の波長条件（1550–1552 nm）に対しても、干渉波を再現し、PSNR 約 30dB の再構成精度を達成した。これは、過去画像に蓄積されていた画像データが、再利用可能な情報源となること、片方の画像を得るために再計算の必要性が無くなることを意味している。

5.2 本研究の意義

本研究の意義は、機械学習を適用することによって、PIC 設計における限られた計算リソースを節約可能であることを実証した点にある。第一に、超解像技術の確立により、低解像度の計算結果から高解像度の分布を正確に再現できるようになった。これにより、本来であれば膨大な計算時間を要する「微細なメッシュでのシミュレーション」そのものを実行することなく、設計に必要な情報を得ることが可能となった。第二に、画像相互変換技術を確立したこと、強度画像あるいは電磁界分布画像のいずれか一方が保存されていれば、他方の物理情報を画像から即座に取得・復元できることを検証した。これは、再シミュレーションの工数を排除できることを意味する。以上の成果は、PIC 設計における計算時間という課題を解消するものであり、過去の設計資産を情報源として再活用することで、光集積回路設計フローを効率化させるアプローチであると言える。

5.3 今後の展望

本研究で得られた知見を基に、今後は以下の発展が期待される。

1. **対象デバイスの拡充:** 現在は 2×2 MMI を主対象としているが、マッハツエンダー干渉計やリング共振器など、より複雑な共振特性を持つデバイスへの適用拡大を進め、モデルの堅牢性を検証する必要がある。

参考文献

- [1] 総務省, “令和 5 年版 情報通信白書,” <https://www.soumu.go.jp/johotsusintokei/whitepaper/ja/r05/pdf/index.html>, 2023, accessed: Dec. 22, 2025.
- [2] K. Wang, X. Ren, W. Chang, L. Lu, D. Liu, and M. Zhang, “Inverse design of digital nanophotonic devices using the adjoint method,” *Photon. Res.*, vol. 8, no. 4, pp. 528–533, Apr 2020. [Online]. Available: <https://opg.optica.org/prj/abstract.cfm?URI=prj-8-4-528>
- [3] “OpenFDTD - オープンソース FDTD 法シミュレーター,” <https://ss023804.stars.ne.jp/OpenFDTD/index.html>, accessed: Dec. 22, 2025.
- [4] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition,” *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [5] C. Dong, C. C. Loy, K. He, and X. Tang, “Learning a deep convolutional network for image super-resolution,” in *Proceedings of the European Conference on Computer Vision (ECCV)*. Springer, 2014, pp. 184–199.
- [6] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros, “Image-to-image translation with conditional adversarial networks,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 1125–1134.
- [7] Q. Huynh-Thu and M. Ghanbari, “Scope of validity of psnr in image/video quality assessment,” *Electronics Letters*, vol. 44, no. 13, pp. 800–801, 2008.
- [8] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, “The unreasonable effectiveness of deep features as a perceptual metric,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 586–595.
- [9] RP Photonics Encyclopedia, “Optical Fiber Communications,” https://www.rp-photonics.com/optical_fiber_communications.html, accessed: Dec. 22, 2025.
- [10] ファイバーラボ株式会社, “光通信用波長帯（通信バンド）の波長範囲と名称,” <https://www.fiberlab.jp/lightwaveband/>.

fiberlabs.co.jp/tech-word/, accessed: Dec. 22, 2025.

- [11] S. Toyota and H. Fukuda, “Simulation time reduction of photonic integrated circuit using super-resolution technique,” in *2023 Conf. Chitose International Forumon Science & Technology 2023 (CIF2023)*, 2023.
- [12] ——, “Application of super-resolution techniques to photonic integrated circuit design,” in *2024 Conf. Lasers Electro-Optics Pacific Rim (CLEO-PR)*, 2024, p. We1A_4.
- [13] bluesky314, “General100 Dataset,” <https://www.kaggle.com/datasets/bluesky314>, 2017, accessed: Dec. 22, 2025.
- [14] S. Toyota and H. Fukuda, “Mutual conversion of simulated images in photonic integrated circuit design,” in *2025 Conf. Chitose International Forumon Science & Technology 2025 (CIF2025)*, 2025.

謝辞

本論文を執筆するにあたり、ご指導を頂いた福田浩教授に心より感謝申し上げます。また、日常の議論を通じて多くの知識や示唆を頂戴いたしました研究室の皆様や副査の高野泰洋教授、山田崇教授にも深く感謝致します。同じく光集積回路の研究に従事し、日々の研究活動において有益な議論を交わしてくれた佐藤広大氏にも深く感謝いたします。

豊田 将大