

令和7年度

修士論文

A horizontal row of 20 empty circles, each with a thin black outline, arranged in a single horizontal line.

A horizontal row of fifteen empty circles, evenly spaced, used as a visual element in a document.

公立千歳科学技術大学大学院理工学研究科

丰田将大

目次

第 1 章	序論	1
1.1	研究背景	1
1.2	研究の動機と着眼点	2
1.3	仮説	3
1.4	研究目的	4
第 2 章	参考技術	5
2.1	時間領域有限差分法 (FDTD 法)	5
2.2	Multi-Mode Interferometer (MMI)	5
2.3	畳み込みニューラルネットワーク (CNN)	6
2.4	超解像技術	6
2.5	画像相互変換技術	7
2.6	評価指標 (PSNR)	7
第 3 章	超解像によるシミュレーションの効率化	8
3.1	はじめに	8
3.2	研究手順	8
3.3	結果	11
3.4	まとめ	13
第 4 章	相互変換	14
4.1	研究背景	14
4.2	研究目的	14
4.3	本論文の構成	14

第 5 章 結論	15
5.1 研究背景	15
5.2 研究目的	15
5.3 本論文の構成	15
参考文献	16
参考文献	16
謝辞	17

第1章

序論

1.1 研究背景

近年、クラウドコンピューティングや5G通信の普及に伴い、世界的に情報通信量が爆発的に増加している。これに伴い、データセンターなどにおける情報処理機器の消費電力増大が課題となっている。この課題を解決する技術として、低消費電力かつ大容量伝送が可能な光集積回路 (PIC: Photonic Integrated Circuit) が注目されている。現在の PIC は、光信号の伝送のみならず、波長分割多重、スイッチング、変調、受光、モニタリングなど多岐にわたる機能をワンチップ上で実現しており、その回路規模は年々大規模化・複雑化の一途をたどっている。

PIC の設計プロセスにおいて、電磁界シミュレーションはデバイスの特性を予測・最適化するために不可欠な工程である。しかし、回路の大規模化に伴い、シミュレーションに必要な計算資源 (メモリや計算時間) の確保が深刻な問題となっている。PIC を実現するために有望視されているプラットフォームシリコンフォトニクスがある。シリコンをコアとし、その酸化膜をクラッドとするため、コアとクラッドの屈折率比を大きくとれるため、PIC の寸法を極限まで小さくすることができる。しかしながら、そのシミュレーションでは、コアとクラッドの屈折率比が小さいことを前提とするビーム伝搬法などを用いることができず、Maxwell 方程式を離散化して解く時間領域有限差分 (FDTD: Finite-Difference Time-Domain) 法を用いる必要がある。FDTD 法を用いて高精度な結果を得るために、計算メッシュの微細化に伴い計算コストは指数関数的に増大する。

この計算コスト増大の問題に対し、設計効率を維持・向上させるためには、従来の設計手法の枠を超えた新たなアプローチが必要不可欠である。特に近年、画像認識や生成の分野で著しい成果を上げている深層学習 (ディープラーニング) 技術の PIC 設計への応用が期待できる。

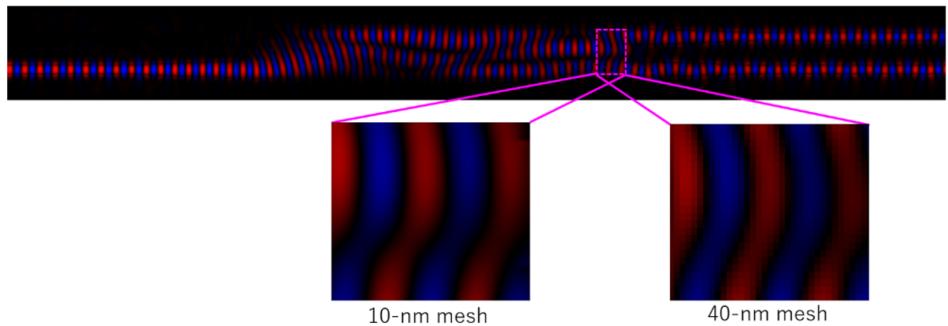


図 1.1 FDTD シミュレーションにおけるメッシュサイズと電磁界分布の解像度の関係。微細なメッシュは高精度だが計算コストが高く、粗いメッシュは高速だが情報量が失われる。

1.2 研究の動機と着眼点

本研究では、PIC 設計の効率化という課題に対し、機械学習を用いた画像処理技術のアプローチから、二つの観点で解決を試みる。

第一のアプローチは、「シミュレーション自体の計算コスト削減」である。FDTD 法などのシミュレーションでは、粗いメッシュを用いれば計算時間は短縮されるが、得られる電磁界分布の解像度が低下し、設計に必要な精度が得られないというトレードオフが存在する（図 1.1 参照）。ここで、低解像度の画像から高解像度の画像を推定する「超解像（Super-Resolution）」技術を適用できれば、粗いメッシュによる高速な計算結果から、微細メッシュと同等の詳細な情報を復元できる可能性がある。

第二のアプローチは、「過去のシミュレーションデータの再利用」である。設計過程では膨大な数のシミュレーションが行われるが、所望の設計パラメータを得たのちは、詳細な 3 次元電磁場分布といった数値データは容量の都合で破棄されることが多く、データの再利用は難しい。この場合であっても確認用の「可視化画像」（電磁界分布画像や強度分布画像）は比較的容量も小さく、残されることが多い。これらの画像データには、デバイス内の光の振る舞いに関する重要な情報が含まれている。もし、この情報が再利用可能になれば、再計算を行うことなく、手元の画像アーカイブから必要な情報を即座に取得することが可能となり、設計プロセスを大幅に効率化できる。本研究では、これら「超解像」と「再利用」という二つのタスクを、機械学習を用いた画像生成・変換問題として統一的に捉え、それぞれの有効性を検証する。

1.3 仮説

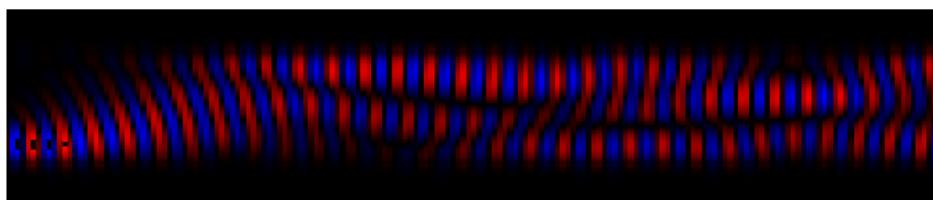
本研究では、それぞれのタスクに対して以下の仮説を立てる。

超解像に関する仮説

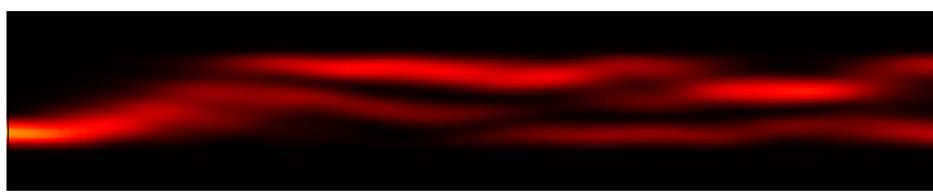
粗いメッシュで計算された低解像度の電磁界分布画像であっても、光の波動としての基本的な振る舞いは保存されている。CNN を用いることで、低解像度・高解像度ペーデータから、メッシュの粗さによって失われた情報を学習し、低解像度のシミュレーション結果に対しても高精度な高解像度画像を再構成できると仮定する。

画像相互変換に関する仮説

電磁界シミュレーションから得られる電磁界分布画像と、強度分布画像の間には、物理的な対応関係が存在する。図 1.2 に示すように、両者は見た目が大きく異なるが、熟練した設計者が視覚的に推測可能であるのと同様に、機械学習によって推測可能であると仮定する。



電磁場画像



強度画像

図 1.2 電磁場画像（上）と対応する強度分布画像（下）の比較。両者の間には物理的な対応関係が存在し、機械学習による相互変換が可能であると仮定する。

さらに、ある波長帯域（例：C バンド）で学習したモデルは、異なる波長帯域（例：O バンド）に対しても、一定の汎用性を持って変換が可能であると考える。

1.4 研究目的

本研究の目的は、機械学習を用いた画像処理技術を適用し、以下の二つの技術を確立することで、PIC 設計の効率化に貢献することである。

1. シミュレーション効率化のための超解像技術の確立

粗いメッシュでの計算結果（低解像度画像）から、微細メッシュ相当の電磁界分布（高解像度画像）を再構成する CNN(Convolutional Neural Network) モデルを構築する。PSNR(Peak Signal-to-Noise Ratio) のような定量的指標を用い、計算時間の短縮が可能であることを実証する。

2. データ再利用のための画像相互変換技術の確立

電磁界分布画像と強度分布画像を相互に変換する Pix2Pix モデルを構築する。視覚的に区別不可能な水準 (PSNR 30 dB 程度) で再構成が可能であることを示し、過去の設計資産の有効活用による設計フロー効率化の可能性を提示する。

第 2 章

参考技術

2.1 時間領域有限差分法 (FDTD 法)

時間領域有限差分法 (Finite-Difference Time-Domain method: FDTD 法) は、マクスウェル方程式を空間および時間領域で差分化し、電磁界の挙動を逐次計算する手法である。

真空中のマクスウェル方程式は以下の 4 式で表される。

$$\nabla \cdot \mathbf{D} = \rho \quad (2.1)$$

$$\nabla \cdot \mathbf{B} = 0 \quad (2.2)$$

$$\nabla \times \mathbf{E} + \frac{\partial \mathbf{B}}{\partial t} = 0 \quad (2.3)$$

$$\nabla \times \mathbf{H} - \frac{\partial \mathbf{D}}{\partial t} = \mathbf{j} \quad (2.4)$$

ここで、 \mathbf{D} は電束密度、 \mathbf{E} は電界、 \mathbf{B} は磁束密度、 \mathbf{H} は磁界、 ρ は電荷密度、 \mathbf{j} は電流密度を表す。

FDTD 法では、Yee 格子と呼ばれるスタガード格子を用い、電界と磁界を空間的・時間的に半ステップずらして配置することで計算を行う。

2.2 Multi-Mode Interferometer (MMI)

光集積回路において、光の分岐・合波やスイッチングを行う重要な素子として多モード干渉計 (Multi-Mode Interferometer: MMI) がある。MMI は、多モード導波路内での高次モード間の干渉を利用して、入力光の像を特定のあいだに自己結像 (Self-Imaging) させる素子である。自己結像の原理により、多モード導波路の長さや幅を適切に設計することで、1 入力 N 出力の分岐や、N 入力 M 出力の合波・分波機能を実現できる。特に、 2×2 MMI カプラは、光通信の大容量化を支え

るデジタルコヒーレント通信において重要な役割を果たしている。例えば、QPSK (Quadrature Phase Shift Keying : 四位相偏移変調) 信号の復調器において、信号光と局発光を干渉させ、90 度の位相差を持つ成分を取り出すために用いられる。MMI の出力における位相バランスや分歧比は、素子の幾何学的寸法に敏感であるため、設計段階における高精度なシミュレーションが不可欠である。

2.3 置み込みニューラルネットワーク (CNN)

2.3.1 概要

置み込みニューラルネットワーク (Convolutional Neural Network: CNN) は、画像認識や画像生成の分野で広く用いられる深層学習モデルの一種である。画像内の局所的な特徴を効率的に抽出し、位置ずれに対する不变性を持つことから、光回路の電磁界分布のような空間的なパターンを持つデータの処理に適している。

2.3.2 各層の役割

- **置み込み層:** 入力画像に対してカーネル（フィルタ）と呼ばれる重み行列をスライドさせながら積和演算を行い、特徴マップを生成する。これにより、電磁界の干渉縞などの局所的特徴を抽出する。
- **プーリング層:** 特徴マップを縮小（ダウンサンプリング）し、計算量の削減や過学習の抑制を行う。
- **全結合層:** 抽出された特徴量を統合し、最終的な出力を行う。

2.4 超解像技術

超解像 (Super-Resolution: SR) とは、低解像度の画像から高解像度の画像を推定・生成する技術である。本研究における超解像タスクでは、粗いメッシュで計算された低解像度な電磁界分布画像を入力とし、微細なメッシュで計算された高解像度な電磁界分布画像を推定することを目指す。SRCNN (Super-Resolution CNN) [1] は、低解像度画像から高解像度画像への非線形なマッピングを学習することで、従来の補間手法（バイキュービック法など）よりも鮮明な画像を再構成することを可能にした。本研究でもこの考え方を応用し、計算コストの削減を図る。

2.5 画像相互変換技術

画像相互変換は、ある画像を別の画像へ変換する技術である。光回路シミュレーションにおいては、電磁界分布と強度分布という異なる物理量の可視化画像が存在する。これらは物理法則によつて紐づいているが、その関係は非線形である。機械学習を用いることで、この複雑な対応関係を学習し、一方の画像から他方の画像を再構成することを試みる。

2.5.1 Pix2Pix

Pix2Pix は、条件付き敵対的生成ネットワーク (Conditional Generative Adversarial Networks: cGAN) に基づいた画像対画像の変換モデルである [2]。Pix2Pix は、入力画像から目的の画像を生成する生成器 (Generator) と、生成された画像が本物か偽物かを判別する識別器 (Discriminator) の 2 つのネットワークで構成される。生成器は識別器を騙すように、識別器は生成器の画像を正しく見破るように学習を進めることで、生成器はより本物に近い高精度な画像を生成できるようになる。本研究における画像変換では、この Pix2Pix のモデルを採用し、電磁界分布画像と強度分布画像のペアデータを用いて学習を行うことで、高度な変換則の獲得を目指す。

2.6 評価指標 (PSNR)

画像の生成精度を定量的に評価する指標として、ピーク信号対雑音比 (Peak Signal-to-Noise Ratio: PSNR) を用いる。 $m \times n$ 画素の正解画像 I と生成画像 K において、平均二乗誤差 (MSE) は以下で定義される。

$$MSE = \frac{1}{mn} \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} [I(i, j) - K(i, j)]^2 \quad (2.5)$$

画像の最大輝度値を MAX_I とすると、PSNR は以下の式で表される。

$$PSNR = 10 \cdot \log_{10} \left(\frac{MAX_I^2}{MSE} \right) = 20 \cdot \log_{10} \left(\frac{MAX_I}{\sqrt{MSE}} \right) \quad (2.6)$$

一般的に、PSNR が 30 dB 以上であれば、視覚的に劣化が気にならない高品質な画像であるとされる。[3]

第 3 章

超解像によるシミュレーションの効率化

3.1 はじめに

本章では、序論で述べた課題を解決するために、機械学習を用いた超解像技術を適用し、低解像度のシミュレーション結果から高解像度の電磁界分布を再構成する手法について述べる。また、提案手法の有効性を検証するために行った、学習時と推論時で波長帯域を変えた結果についても報告する。

3.2 研究手順

3.2.1 シミュレーションデバイスとデータ生成

機械学習の学習データとして電磁界パターンを収集するため、光回路の FDTD シミュレーションを行った。

デバイス構造

本研究では、干渉計ベースのシンプルな構造を採用した。具体的には、 2×2 MMI から 1 つの入力導波路と 2 つの出力導波路を取り外したデバイスを今回は使用している。(図 3.1)。この構造を用いることで、機械学習の学習素材となる電磁界パターンの画像を取得している。

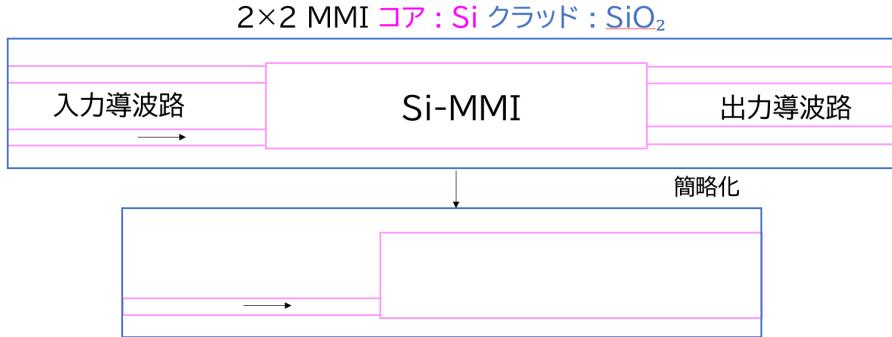


図 3.1 本研究で使用した学習データ生成用のデバイス。

計算条件とメッシュサイズ

シミュレーションには 3 次元 FDTD 法を用いた。以下のメッシュサイズを設定した。

- **20 nm メッシュ:** 高解像度 (High-Resolution: HR)。教師データとして使用。
- **40 nm メッシュ:** 低解像度 (Low-Resolution: LR)。入力データとして使用。

メッシュサイズを細かくするほど計算時間は指数関数的に増大する。20nm メッシュでの計算と比較して、40nm メッシュでは計算時間を短縮できるため、この低解像度画像から高解像度画像を復元できれば設計効率は大きく向上する。

3.2.2 SRCNN モデルと学習プロセス

本研究では、超解像アルゴリズムとして SRCNN を採用した。SRCNN は、低解像度画像と高解像度画像のペアを学習させることで、画像の特徴量を抽出し、低解像度画像から高解像度画像を再構成する。

データセットの構築

シミュレーションで得られた電磁界分布画像を、それぞれ 20 枚の画像に分割した。分割された画像のうち、電磁界がほとんど存在しない部分は、学習データとして無意味でありノイズとなる可能性があるため除外した。残った画像ペアを以下のグループに分割した (図 3.2)。

ネットワーク構造とパラメータ

構築した SRCNN モデルの構造およびハイパーパラメータは以下の通りである。

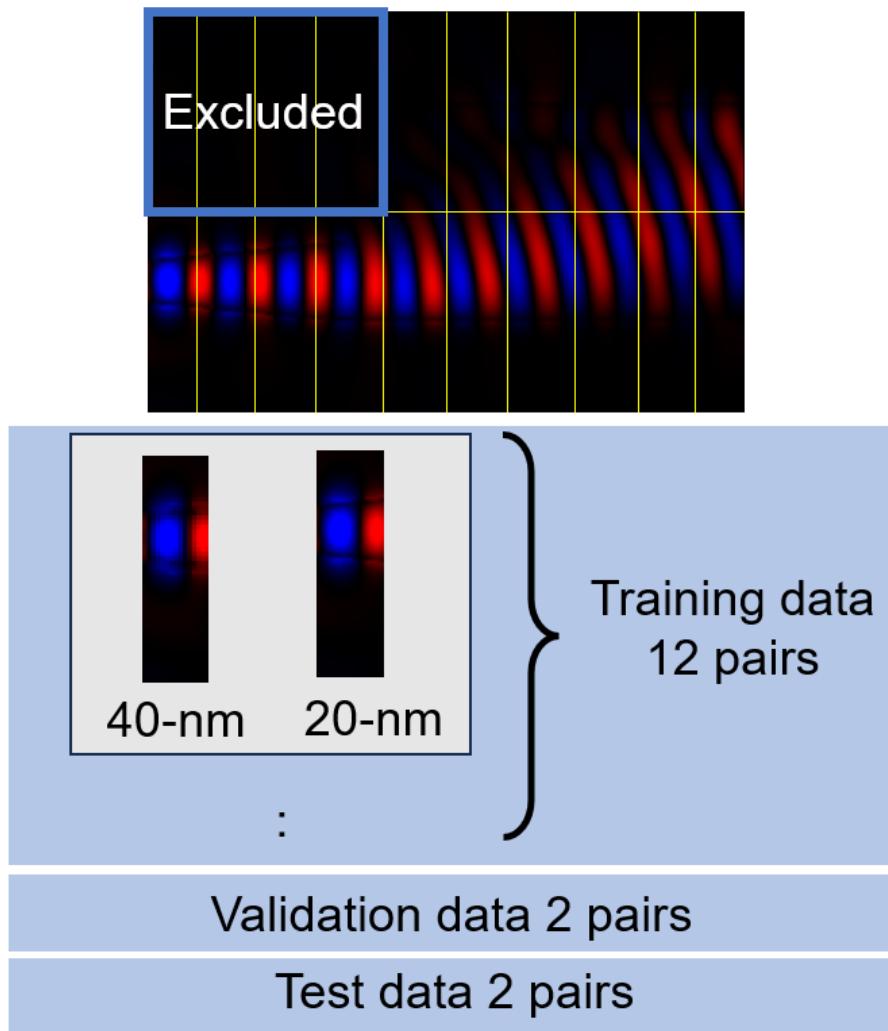


図 3.2 SRCNN の学習に使用したデータセット。

- 第 1 層（畳み込み層）：フィルタ数 16, フィルタサイズ 3×3 , 活性化関数 ReLU
- 第 2 層（畳み込み層）：フィルタ数 3, フィルタサイズ 3×3 , 活性化関数 ReLU
- 最適化手法: Adam
- 損失関数: 平均二乗誤差 (MSE)
- 評価指標: PSNR
- エポック数: 15000
- バッチサイズ: 32

3.2.3 検証手順

提案手法の性能と適用範囲を検証するため、以下の 2 つの検証を行った。

1. 学習時と同じ波長帯のシミュレーション画像を超解像

C バンド（波長 1550nm 帯）のシミュレーション結果を学習データとして用い、同帯域のシミュレーション画像の超解像を行う。

2. 学習時とは異なる波長帯のシミュレーション画像を超解像

C バンドのデータで学習したモデルを用いて、異なる波長帯域である O バンド（波長 1300 nm 帯）のシミュレーション画像の超解像を行う。学習時とは異なる条件下でのモデルの汎用性を検証する。

また、比較対象として、従来の画像補間手法であるバイリニア補間 (Bilinear interpolation) およびバイキュービック補間 (Bicubic interpolation) による結果とも比較を行った。

3.3 結果

3.3.1 C バンド学習モデルの評価

C バンドのシミュレーション画像を学習データとして用いたモデルの評価を行った。結果として、PSNR は劇的に向上し、約 8dB の改善が見られた（図 3.3）。再構成された画像の PSNR は 30dB を超えており、視覚的にも高解像度画像と遜色のないレベルまで品質が向上した。これにより、SRCNN の高い再構成能力が確認された。

3.3.2 異波長 (O バンド) への適用結果

C バンドのデータで学習したモデルを用いて、O バンドのシミュレーション画像の超解像を行った。結果として、C バンドでの推論時と同等の高い PSNR 値が得られた（図 3.4）。波長が異なっても、光の干渉や伝搬といった物理現象に由来する画像の特徴は共通しているため、モデルがその特徴を捉えて汎化できたと考えられる。この結果は、一度モデルを構築すれば、異なる波長条件のシミュレーションに対しても再学習なしで適用できる可能性を示している。

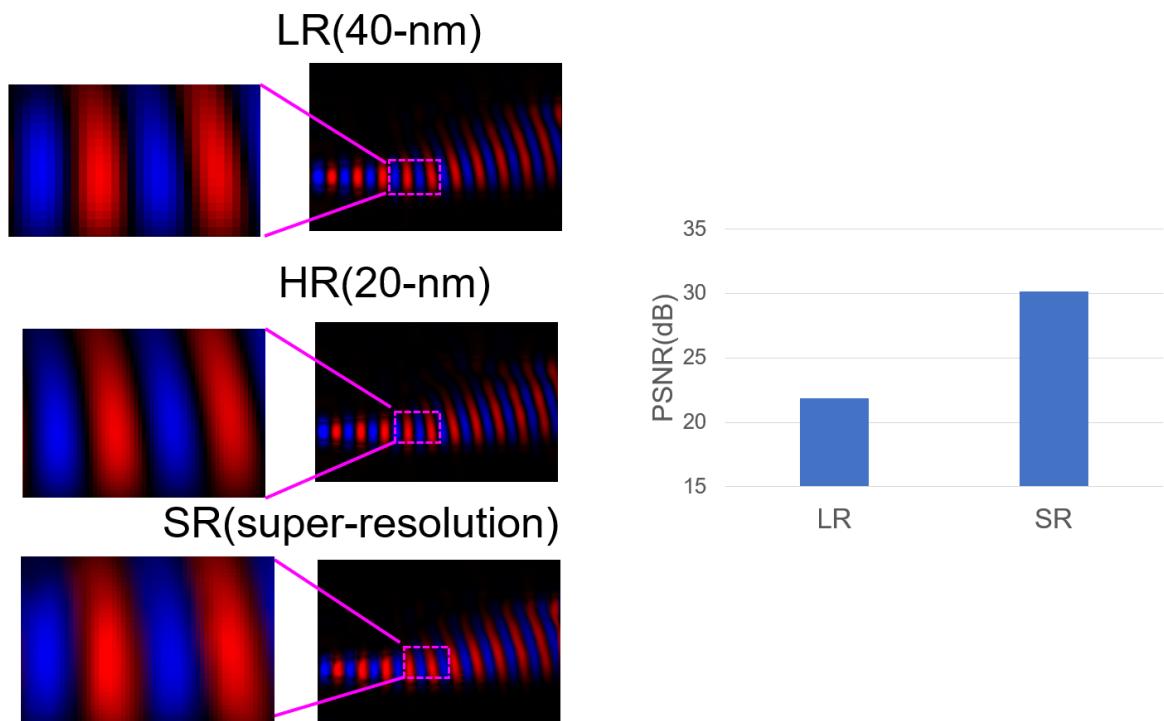


図 3.3 C バンドを学習したモデルを用いて C バンド画像の超解像を行った結果。

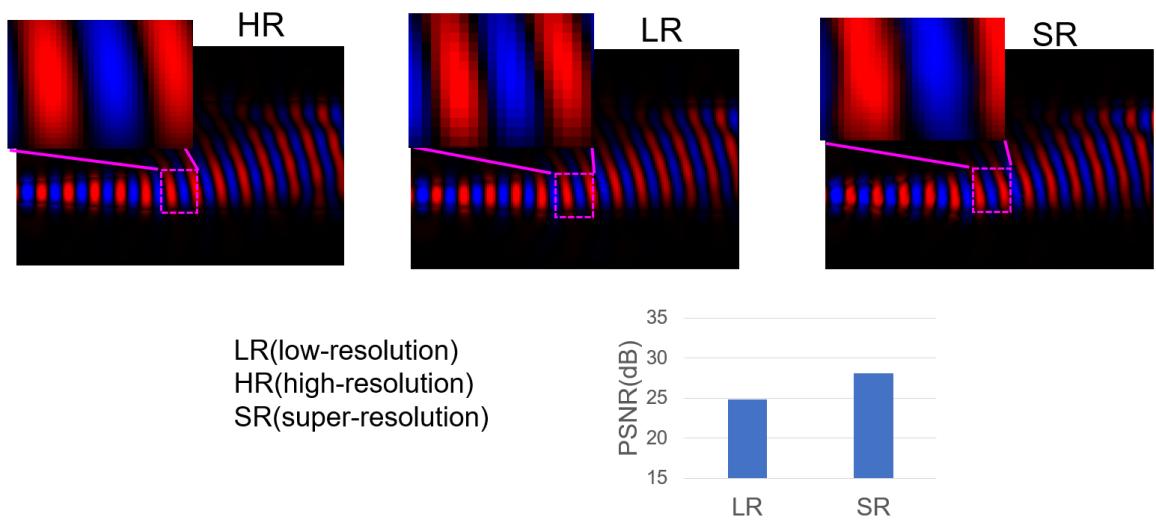


図 3.4 C バンドを学習したモデルを用いて O バンド画像の超解像を行った結果。

3.3.3 従来手法との比較

SRCNN による超解像と、従来の補間手法 (バイリニア、バイキューピック) による結果を比較した。図 3.5 に示すように、従来手法もある程度の画質改善効果はあるものの、SRCNN と比較するとその効果は小さい。SRCNN は、学習データから画像の特徴を学習することで、単なる幾何学的な補間よりも高度な高解像度化を実現していると言える。

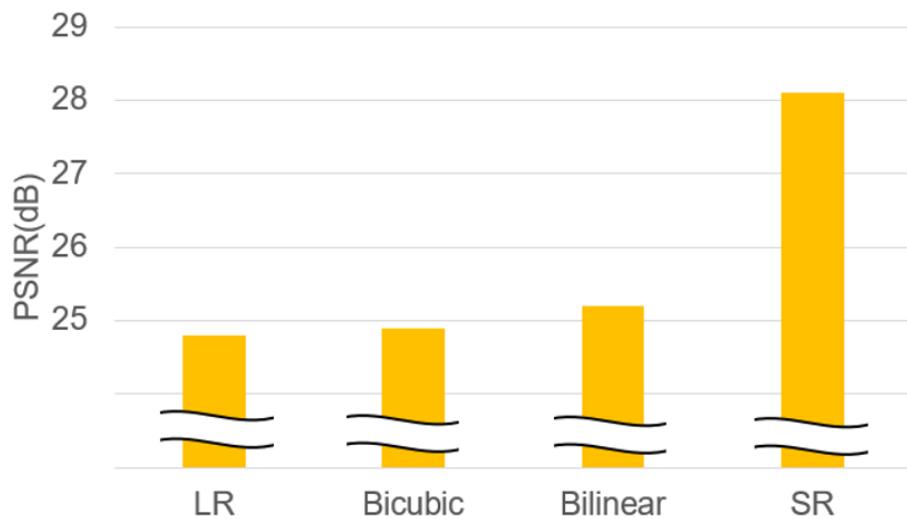


図 3.5 SRCNN と従来の補間手法 (バイリニア、バイキューピック) による PSNR の比較。

3.4 まとめ

本章では、PIC 設計における計算リソース削減を目的として、SRCNN を用いたシミュレーション画像の超解像手法を提案・検証した。検証の結果、SRCNN は従来の補間手法よりも優れた再構成能力を示した。特に、学習時と同じ波長帯のものを超解像したとき、PSNR 30dB を超える高精度な画像再構成が可能であることを確認した。さらに、C バンドで学習したモデルが O バンドのシミュレーション画像に対しても有効であることが示され、提案手法の汎用性が実証された。これらの結果は、SRCNN が将来の大規模かつ複雑な PIC 設計において、計算コストを削減するための重要な技術となり得ることを示している。

第4章

相互変換

4.1 研究背景

4.2 研究目的

4.3 本論文の構成

第5章

結論

5.1 研究背景

5.2 研究目的

5.3 本論文の構成

参考文献

- [1] C. Dong, C. C. Loy, K. He, and X. Tang, “Learning a deep convolutional network for image super-resolution,” in *Proceedings of the European Conference on Computer Vision (ECCV)*. Springer, 2014, pp. 184–199.
- [2] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros, “Image-to-image translation with conditional adversarial networks,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 1125–1134.
- [3] Q. Huynh-Thu and M. Ghanbari, “Scope of validity of psnr in image/video quality assessment,” *Electronics Letters*, vol. 44, no. 13, pp. 800–801, 2008.

謝辞

(ここに謝辞を書く)