


令和7年度

修 士 論 文



公立千歳科学技術大学大学院理工学研究科

豊田将大

目次

第 1 章	序論	1
1.1	研究背景	1
1.2	研究の動機と着眼点	2
1.3	仮説	3
1.4	研究目的	4
第 2 章	参考技術	5
2.1	光回路の数値解析手法	5
2.2	多モード干渉計 (MMI)	6
2.3	畳み込みニューラルネットワーク (CNN)	7
2.4	超解像および画像再構成技術	7
2.5	数値計算手法	9
第 3 章	超解像	11
3.1	研究背景	11
3.2	研究目的	11
3.3	本論文の構成	11
第 4 章	相互変換	12
4.1	研究背景	12
4.2	研究目的	12
4.3	本論文の構成	12
第 5 章	結論	13
5.1	研究背景	13

5.2	研究目的	13
5.3	本論文の構成	13
	謝辞	14

第 1 章

序論

1.1 研究背景

近年、クラウドコンピューティングや 5G 通信の普及に伴い、世界的に情報通信量が爆発的に増加している。これに伴い、データセンターなどにおける情報処理機器の消費電力増大が課題となっている。この課題を解決する技術として、低消費電力かつ大容量伝送が可能な光集積回路 (PIC: Photonic Integrated Circuit) が注目されている。現在の PIC は、光信号の伝送のみならず、波長分割多重、スイッチング、変調、受光、モニタリングなど多岐にわたる機能をワンチップ上で実現しており、その回路規模は年々大規模化・複雑化の一途をたどっている。

PIC の設計プロセスにおいて、電磁界シミュレーションはデバイスの特性を予測・最適化するために不可欠な工程である。しかし、回路の大規模化に伴い、シミュレーションに必要な計算資源 (メモリや計算時間) の確保が深刻な問題となっている。PIC を実現するために有望視されているプラットフォームシリコンフォトニクスがある。シリコンをコアとし、その酸化膜をクラッドとするため、コアとクラッドの屈折率比を大きくとれるため、PIC の寸法を極限まで小さくすることができる。しかしながら、そのシミュレーションでは、コアとクラッドの屈折率比が小さいことを前提とするビーム伝搬法などを用いることができず、Maxwell 方程式を離散化して解く時間領域有限差分 (FDTD: Finite-Difference Time-Domain) 法を用いる必要がある。FDTD 法を用いて高精度な結果を得るためには、計算メッシュの微細化に伴い計算コストは指数関数的に増大する。

この計算コスト増大の問題に対し、設計効率を維持・向上させるためには、従来の設計手法の枠を超えた新たなアプローチが必要不可欠である。特に近年、画像認識や生成の分野で著しい成果を上げている深層学習 (ディープラーニング) 技術の PIC 設計への応用が期待できる。




図 1.1 FDTD シミュレーションにおけるメッシュサイズと電磁界分布の解像度の関係。微細なメッシュは高精度だが計算コストが高く、粗いメッシュは高速だが情報量が失われる。

1.2 研究の動機と着眼点

本研究では、PIC 設計の効率化という課題に対し、機械学習を用いた画像処理技術のアプローチから、二つの観点で解決を試みる。

第一のアプローチは、「シミュレーション自体の計算コスト削減」である。FDTD 法などのシミュレーションでは、粗いメッシュを用いれば計算時間は短縮されるが、得られる電磁界分布の解像度が低下し、設計に必要な精度が得られないというトレードオフが存在する（図 1.1 参照）。ここで、低解像度の画像から高解像度の画像を推定する「超解像（Super-Resolution）」技術を適用できれば、粗いメッシュによる高速な計算結果から、微細メッシュと同等の詳細な情報を復元できる可能性がある。

第二のアプローチは、「過去のシミュレーションデータの再利用」である。設計過程では膨大な数のシミュレーションが行われるが、所望の設計パラメータを得たのちは、詳細な 3 次元電磁場分布といった数値データは容量の都合で破棄されることが多く、データの再利用は難しい。この場合であっても確認用の「可視化画像」（電磁界分布画像や強度分布画像）は比較的容量も小さく、残されることが多い。これらの画像データには、デバイス内の光の振る舞いに関する重要な情報が含まれている。もし、この情報が再利用可能になれば、再計算を行うことなく、手元の画像アーカイブから必要な情報を即座に取得することが可能となり、設計プロセスを大幅に効率化できる。本研究では、これら「超解像」と「再利用」という二つのタスクを、機械学習を用いた画像生成・変換問題として統一的に捉え、それぞれの有効性を検証する。

1.3 仮説


本研究では、それぞれのタスクに対して以下の仮説を立てる。

超解像に関する仮説


粗いメッシュで計算された低解像度の電磁界分布画像であっても、光の波動としての基本的な振る舞いは保存されている。CNN を用いることで、低解像度・高解像度ペアデータから、メッシュの粗さによって失われた情報を学習し、低解像度のシミュレーション結果に対しても高精度な高解像度画像を再構成できると仮定する。

画像相互変換に関する仮説

電磁界シミュレーションから得られる電磁界分布画像と、強度分布画像の間には、物理的な対応関係が存在する。図 1.2 に示すように、両者は見た目が大きく異なるが、熟練した設計者が視覚的に推測可能であるのと同様に、機械学習によって推測可能であると仮定する。



電磁場画像



強度画像

図 1.2 電磁場画像（上）と対応する強度分布画像（下）の比較。両者の間には物理的な対応関係が存在し、機械学習による相互変換が可能であると仮定する。

さらに、ある波長帯域 (例：C バンド) で学習したモデルは、異なる波長帯域 (例：O バンド) に対しても、一定の汎用性を持って変換が可能であると考ええる。

1.4 研究目的

本研究の目的は、機械学習を用いた画像処理技術を適用し、以下の二つの技術を確立することで、PIC 設計の効率化に貢献することである。

1. シミュレーション効率化のための超解像技術の確立

粗いメッシュでの計算結果 (低解像度画像) から、微細メッシュ相当の電磁界分布 (高解像度画像) を再構成する CNN(Convolutional Neural Network) モデルを構築する。PSNR(Peak Signal-to-Noise Ratio) のような定量的指標を用い、計算時間の短縮が可能であることを実証する。

2. データ再利用のための画像相互変換技術の確立

電磁界分布画像と強度分布画像を相互に変換する Pix2Pix モデルを構築する。視覚的に区別不可能な水準 (PSNR 30 dB 程度) で再構成が可能であることを示し、過去の設計資産の有効活用による設計フロー効率化の可能性を提示する。

第 2 章

参考技術

本章では、本研究で用いる主要な技術および理論について述べる。まず、光回路の数値解析手法として、本研究の背景となる FDTD 法およびデータ生成に用いる FMM 法について解説する。次に、解析対象である MMI カプラの原理について述べる。続いて、本研究の核となる機械学習技術として、畳み込みニューラルネットワーク（CNN）および、それを応用した超解像・画像再構成技術について説明する。最後に、解析結果の評価に用いる数値計算手法について触れる。

2.1 光回路の数値解析手法

光集積回路の設計においては、マクスウェル方程式に基づいた厳密な電磁界シミュレーションが不可欠である。本研究に関連する主要な手法として、時間領域有限差分法（FDTD 法）とフィルムモード整合法（FMM 法）について述べる。

2.1.1 時間領域有限差分法 (FDTD 法)

時間領域有限差分法（Finite-Difference Time-Domain method: FDTD 法）は、マクスウェル方程式を空間および時間領域で差分化し、電磁界の挙動を逐次計算する手法である [?]

真空中のマクスウェル方程式は以下の 4 式で表される。

$$\nabla \cdot \mathbf{D} = \rho \quad (2.1)$$

$$\nabla \cdot \mathbf{B} = 0 \quad (2.2)$$

$$\nabla \times \mathbf{E} + \frac{\partial \mathbf{B}}{\partial t} = 0 \quad (2.3)$$

$$\nabla \times \mathbf{H} - \frac{\partial \mathbf{D}}{\partial t} = \mathbf{j} \quad (2.4)$$

ここで、 \mathbf{D} は電束密度、 \mathbf{E} は電界、 \mathbf{B} は磁束密度、 \mathbf{H} は磁界、 ρ は電荷密度、 \mathbf{j} は電流密度を表す。

FDTD 法では、Yee 格子と呼ばれるスタガード格子を用い、電界と磁界を空間的・時間的に半ステップずらして配置することで計算を行う。任意の形状や広帯域な波長特性を一度に解析できる利点がある一方で、精度を確保するためにメッシュサイズを波長の数十分の一以下にする必要があり、計算コスト（メモリと計算時間）が指数関数的に増大するという課題がある。

2.1.2 フィルムモード整合法 (FMM 法)

フィルムモード整合法 (Film Mode Matching method: FMM 法) は、導波路を伝搬方向に対して均一な複数のセクションに分割し、各セクションにおける固有モードの重ね合わせとして電磁界を表現する手法である。各セクションの界面において電磁界の接線成分が連続となるように境界条件を適用し、散乱行列 (S 行列) などを用いて全体の伝搬特性を解析する。FMM 法は、MMI のような矩形構造の組み合わせで表現できるデバイスに対しては、FDTD 法と比較して高速に計算が可能であるという特徴を持つ。本研究の一部では、学習データの効率的な生成に本手法が用いられている。

2.2 多モード干渉計 (MMI)

光集積回路において、光の分岐・合波やスイッチングを行う重要な素子として多モード干渉計 (Multi-Mode Interferometer: MMI) がある。

2.2.1 動作原理と用途

MMI は、多モード導波路内での高次モード間の干渉を利用して、入力光の像を特定のあいちに自己結像 (Self-Imaging) させる素子である。自己結像の原理により、多モード導波路の長さや幅を適切に設計することで、1 入力 N 出力の分岐や、N 入力 M 出力の合波・分波機能を実現できる。

特に、 2×2 MMI カプラは、光通信の大容量化を支えるデジタルコヒーレント通信において重要な役割を果たしている。例えば、QPSK (Quadrature Phase Shift Keying: 四位相偏移変調) 信号の復調器において、信号光と局発光を干渉させ、90 度の位相差を持つ成分を取り出すために用いられる。MMI の出力における位相バランスや分岐比は、素子の幾何学的寸法に敏感であるため、設計段階における高精度なシミュレーションが不可欠である。

2.3 畳み込みニューラルネットワーク (CNN)

2.3.1 概要

畳み込みニューラルネットワーク (Convolutional Neural Network: CNN) は、画像認識や画像生成の分野で広く用いられる深層学習モデルの一種である。画像内の局所的な特徴 (エッジ、テクスチャ、周期構造など) を効率的に抽出し、位置ずれに対する不変性を持つことから、光回路の電磁界分布のような空間的なパターンを持つデータの処理に適している。

2.3.2 各層の役割

- **畳み込み層:** 入力画像に対してカーネル (フィルタ) と呼ばれる重み行列をスライドさせながら積和演算を行い、特徴マップを生成する。これにより、電磁界の干渉縞などの局所的特徴を抽出する。
- **プーリング層:** 特徴マップを縮小 (ダウンサンプリング) し、計算量の削減や過学習の抑制を行う。
- **全結合層:** 抽出された特徴量を統合し、最終的な出力を行う。なお、画像の生成や変換を行うモデルでは、アップサンプリング層を用いて元の画像サイズへ復元する構成がとられることが多い。

2.4 超解像および画像再構成技術

本研究では、CNN を応用した画像処理技術として、超解像と画像相互変換 (再構成) の 2 つのアプローチに着目する。

2.4.1 超解像技術 (Super-Resolution)

超解像 (Super-Resolution: SR) とは、低解像度の画像から高解像度の画像を推定・生成する技術である。Dong らによって提案された SRCNN (Super-Resolution CNN) [?] は、低解像度画像から高解像度画像への非線形なマッピングを学習することで、従来の補間手法 (バイキュービック法など) よりも鮮明な画像を再構成することを可能にした。本研究における超解像タスクでは、粗いメッシュで計算された低解像度な電磁界分布画像を入力とし、微細なメッシュで計算された高解像度な電磁界分布画像を推定することを目指す。

2.4.2 画像相互変換・再構成 (Image Conversion)

画像相互変換は、あるドメインの画像を別のドメインの画像へ変換する技術である。光回路シミュレーションにおいては、電磁界分布 (位相情報を含む干渉パターン) と光強度分布 (パワーの流れ) という異なる物理量の可視化画像が存在する。これらは物理法則 (マクスウェル方程式) によって紐づいているが、その関係は非線形である。CNN を用いることで、この複雑な対応関係を学習し、一方の画像から他方の画像を再構成することが可能となる。これにより、保存されている可視化画像データからの物理情報の復元や、異なる可視化形式への変換が実現できる。

2.4.3 Pix2Pix

Pix2Pix は、Isola らによって提案された、条件付き敵対的生成ネットワーク (Conditional Generative Adversarial Networks: cGAN) に基づいた画像対画像の変換 (Image-to-Image Translation) モデルである [?]. Pix2Pix は、入力画像から目的の画像を生成する生成器 (Generator) と、生成された画像が本物か偽物かを判別する識別器 (Discriminator) の 2 つのネットワークで構成される。生成器は識別器を騙すように、識別器は生成器の画像を正しく見破るように学習を進める (敵対的学習) ことで、生成器はより本物に近い高精度な画像を生成できるようになる。本研究における画像相互変換タスクでは、この Pix2Pix のモデルを採用し、電磁界分布画像と強度分布画像のペアデータを用いて学習を行うことで、物理法則に基づいた高度な変換則の獲得を目指す。

2.4.4 評価指標 (PSNR)

画像の生成精度を定量的に評価する指標として、ピーク信号対雑音比 (Peak Signal-to-Noise Ratio: PSNR) を用いる。 $m \times n$ 画素の正解画像 I と生成画像 K において、平均二乗誤差 (MSE) は以下で定義される。

$$MSE = \frac{1}{mn} \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} [I(i, j) - K(i, j)]^2 \quad (2.5)$$

画像の最大輝度値を MAX_I (通常は 255) とすると、PSNR は以下の式で表される。

$$PSNR = 10 \cdot \log_{10} \left(\frac{MAX_I^2}{MSE} \right) = 20 \cdot \log_{10} \left(\frac{MAX_I}{\sqrt{MSE}} \right) \quad (2.6)$$

一般的に、PSNR が 30 dB 以上であれば、視覚的に劣化が気にならない高品質な画像であるとされる。

2.5 数値計算手法

2.5.1 カーブフィッティング

シミュレーション結果の画像から物理的な特性値 (位相差など) を抽出するために、カーブフィッティング (曲線あてはめ) を用いる。本研究では、導波路内を伝搬する光の波形解析において、画像の画素値列 (離散データ) から光の位相情報を推定するために利用する。光波は正弦波としてモデル化できるため、振幅 A 、角周波数 ω 、位相 ϕ 、オフセット C をパラメータとする関数 $f(x) = A \sin(\omega x + \phi) + C$ へのフィッティング問題となる。

2.5.2 Levenberg-Marquardt 法

非線形最小二乗法の解法として、Levenberg-Marquardt 法 (レーベンバーグ・マルカート法) を用いる。この手法は、最急降下法とガウス・ニュートン法を組み合わせたアルゴリズムであり、初期値依存性を低減しつつ安定して最適解を探索できる特徴がある。更新式は以下のように表される。

$$\mathbf{x}_{k+1} = \mathbf{x}_k - (\mathbf{J}_k^T \mathbf{J}_k + \lambda \mathbf{I})^{-1} \mathbf{J}_k^T \mathbf{r}_k \quad (2.7)$$

ここで、 \boldsymbol{x} はパラメータベクトル、 \boldsymbol{J} はヤコビ行列、 \boldsymbol{r} は残差ベクトル、 \boldsymbol{I} は単位行列、 λ はダンピング係数である。

第 3 章

超解像

3.1 研究背景

3.2 研究目的

3.3 本論文の構成

第 4 章

相互変換

4.1 研究背景

4.2 研究目的

4.3 本論文の構成

第 5 章

結論

5.1 研究背景

5.2 研究目的

5.3 本論文の構成

謝辞

(ここに謝辞を書く)